

Análisis y Predicción del Riesgo de Reclamaciones en Seguros de Automóviles

Un estudio con datos de Porto Seguro

UOC

Marc Román Porras

Máster Universitario en
Ciencia de Datos

Área de conocimiento 1

Tutor/a de TF

Rafael Luque Ocaña

**Profesor/a responsable de
la asignatura**

Susana Acedo

Mayo de 2025

Universitat Oberta
de Catalunya



Esta obra está sujeta a una licencia de Reconocimiento-
NoComercial-SinObraDerivada [3.0 España de Creative
Commons](https://creativecommons.org/licenses/by-nc-nd/3.0/es/)

Ficha del Trabajo Final

Título del trabajo:	Análisis y Predicción del Riesgo de Reclamaciones en Seguros de Automóviles. Un Estudio con Datos de Porto Seguro
Nombre del autor/a:	Marc Román Porras
Nombre del Tutor/a de TF:	Rafael Luque Ocaña
Nombre del/de la PRA:	Susana Acedo
Fecha de entrega:	05/2025
Titulación o programa:	Máster Universitario en Ciencia de Datos
Área del Trabajo Final:	Área de conocimiento 1
Idioma del trabajo:	Castellano
Palabras clave	Data Exploration and Feature Engineering, Risk Assessment, Imbalanced Data Handling, Supervised Machine Learning, Explainable AI
Resumen del Trabajo	
El sector asegurador enfrenta desafíos constantes en la evaluación del riesgo de siniestralidad, un aspecto clave que impacta en la rentabilidad, la asignación de primas y la gestión de capital. La creciente regulación en este ámbito, con normativas como Solvencia II, impone estrictos requisitos en términos de solvencia, gobernanza del riesgo y transparencia financiera, exigiendo modelos robustos y auditables para la estimación del riesgo asegurador. El avance de las técnicas de <i>Machine Learning</i> y el modelado estadístico ha permitido mejorar la predicción del riesgo de siniestralidad, aprovechando datos históricos del sector. En este proyecto, se emplea el conjunto de datos <i>Porto Seguro Safe Driver Prediction</i> para construir modelos supervisados bajo un escenario de desbalance estructural severo. Aunque se aplican estrategias de calibración, selección empírica de predictores y ajuste al desbalanceo, el rendimiento predictivo queda limitado por la baja separabilidad estadística del espacio de variables. La ofuscación, la escasa granularidad y el bajo poder informativo de los predictores imponen una cota superior al rendimiento alcanzable, independientemente de la arquitectura empleada. Además del rendimiento predictivo, la propuesta enfatiza la explicabilidad, robustez	

y cumplimiento con carácter regulatorio. Pese a las limitaciones del *dataset* (ofuscación, desbalanceo y baja capacidad predictiva), es posible construir una solución estable, calibrada y explicable. El modelo XGBoost calibrado actúa como un primer filtro útil en la toma de decisiones aseguradoras, y la arquitectura desarrollada es escalable y alineada con los requisitos regulatorios y operativos del sector.

Abstract

The insurance sector faces ongoing challenges in accurately assessing claim risk, a key factor that directly impacts profitability, premium allocation, and capital management. Increasing regulatory pressure—through frameworks such as Solvency II—imposes strict requirements regarding solvency, risk governance, and financial transparency, demanding the use of robust and auditable models for insurance risk estimation.

Advances in machine learning and statistical modeling techniques have improved accident risk prediction by leveraging historical data from the sector. In this project, the Porto Seguro Safe Driver Prediction dataset is used to build supervised models under a severe structural imbalance scenario. Although calibration strategies, empirical predictor selection, and imbalance adjustment are applied, predictive performance is limited by the low statistical separability of the variable space. Obfuscation, limited granularity, and the low informative power of the predictors impose an upper limit on achievable performance, regardless of the architecture used.

In addition to predictive performance, the proposal emphasizes explainability, robustness, and regulatory compliance. Despite the dataset's limitations (obfuscation, imbalance, and low predictive capacity), it is possible to build a stable, calibrated, and explainable solution. The calibrated XGBoost model acts as a useful first filter in insurance decision-making, and the developed architecture is scalable and aligned with the regulatory and operational requirements of the sector.

Índice

1.INTRODUCCIÓN	7
1.1.Contexto y justificación del Trabajo	7
1.1.1.Motivación	8
1.2.Objetivos del Trabajo	8
1.2.1.Objetivo principal (Hipótesis de investigación):	8
1.2.2.Objetivos parciales (Preguntas de investigación y pasos previos):	9
1.3.Impacto en sostenibilidad, ético-social y de diversidad	10
1.3.1.Impacto en sostenibilidad (ODS)	10
1.3.2.Impacto ético-social	10
1.3.3.Impacto en diversidad	11
1.3.4.Riesgos del proyecto	11
1.4.Enfoque y método seguido	12
1.4.1.Estrategia de investigación	12
1.4.2.Descripción de la metodología de trabajo	12
1.4.3.Justificación de la metodología	13
1.4.4.Alcance de la investigación	13
1.5.Planificación del trabajo	14
1.6.Breve resumen de productos obtenidos	15
1.7.Breve descripción de otros capítulos de la memoria	15
2.ESTADO DEL ARTE	17
3.MATERIALES Y MÉTODOS	20
3.1. Riesgo de siniestralidad – planteamiento de medición	20
3.2. Carga y preparación inicial del <i>dataset</i>	21
3.2.1. Tipología de las variables	21
3.3. Análisis exploratorio de datos (EDA)	22
3.3.1. Análisis Univariante del Target	23
3.3.2. Análisis Bivariante	23
3.3.3. Correlación entre variables cuantitativas	24
3.4. Preparación de datos	25
3.4.1. Valores NA	25
3.4.2. Selección de variables	27
3.4.2.1. Métrica agregada para decisión	27

3.4.2.2. Dicotomización del ranking mediante Otsu	30
3.5. Modelización	32
3.5.1. Regresión Logística	32
3.5.2. XGBoost	33
3.5.3. LightGBM	34
3.5.4. TabNet	34
3.5.5. Selección de hiperparámetros	35
3.5.5.1. Naturaleza y rol de los hiperparámetros en los modelos considerados	35
3.5.5.2. Optuna como herramienta de optimización automática de hiperparámetros	36
3.5.6. Preparación del conjunto de datos para entrenamiento	36
3.5.6.1. División en subconjuntos: entrenamiento, validación y test	36
3.5.6.2. Preprocesamiento de variables para modelizar	37
3.6. Entrenamiento y Evaluación	37
3.6.1. Proceso de entrenamiento	37
3.6.2. Mejor modelo	39
3.6.2.1. Modelos basados en árboles de decisión ensamblados (XGBoost y LightGBM)	39
3.6.2.2. Regresión logística	39
3.6.2.3. TabNet	40
3.6.2.4. Reflexión final sobre los resultados obtenidos y limitaciones del modelado supervisado	40
3.6.2.5. Diagnóstico umbral-dependiente del clasificador: análisis de la matriz de confusión del mejor modelo	42
3.6.3. Calibración de la curva de probabilidades	44
3.6.3.1. Del siniestro al "riesgo de siniestro": Calibración del espacio de probabilidad	44
3.7. Explicabilidad	46
3.7.1. Análisis de una predicción individual con LIME	47
3.7.2. Análisis SHAP local	49
3.7.3. Análisis SHAP global	50
3.8. Producción (basis): despliegue y operacionalización del modelo de siniestralidad	52
3.8.1. Descripción técnica y funcional de los componentes	53
4. RESULTADOS	57
5. CONCLUSIONES Y TRABAJOS FUTUROS	62
6. GLOSARIO	66
7. BIBLIOGRAFÍA	70
8. ANEXOS	72

Análisis exploratorio de datos (EDA)	72
Análisis Bivariante: Variables Categóricas vs Target	72
Análisis Bivariante: Variables Cuantitativas vs Target	75
Selección de Variables – Cálculo de indicadores por variable	77
Cálculo de indicadores por variable	77
Coeficiente de Gini	77
Information Value (IV)	78
Importancia por permutación	80
Variance Inflation Factor (VIF)	81
Kolmogorov-Smirnov (KS)	82
OPTUNA - detalle:	83
Enfoque metodológico: TPE + Pruning	83
Mecanismo de pruning (early stopping)	84
Formalización del problema	84
Espectro de Hiperparámetros y valor final tras Optuna	84
Proceso de entrenamiento – Interpretación de resultados	85
Métricas de error para Datos Desbalanceados sobre target binario	85
Idiosincrasia de la Matriz de Confusión vs. Métricas AUC como elemento clave	85
Matriz de confusión: Precision y Recall como métricas clave en un clasificador desbalanceado	87
Calibración de la curva de probabilidad	88
Regresión Isotónica	88
Aplicación sobre el mejor modelo en el contexto del proyecto	89
Explicabilidad (LIME y SHAP)	89
Interpretación local del modelo mediante LIME (Local Interpretable Model-agnostic Explanations)	89
Interpretación del modelo mediante SHAP	91

Lista de Figuras

Figura 1. Diagrama de Gantt del ciclo del proyecto.	15
Figura 2. Importancia relativa visual de las líneas de estado del arte del proyecto.	19
Figura 3. Distribución de los tipos de variables en el dataset, tras tratamiento.	22
Figura 4. Distribución de la variable objetivo “target” del evento de siniestro	23
Figura 5. <i>Heatmap</i> de la Matriz de Correlación de Pearson entre variables cuantitativas	24
Figura 6. Visualización genérica de sensibilidad de variables con nan’s.	25
Figura 7. Visualización del efecto de la imputación sobre las variables cuantitativas que lo requieren.	26
Figura 8. Pipeline del flujo diseñado para la selección de variables con relevancia sobre el <i>target</i>	27
Figura 9. Relación las métricas agregadas generadas (Score1 y Score2).	28
Figura 10. Visualización del umbral de Otsu sobre Sum Gini + IV	31
Figura 11. Visualización final de predictores (métricas agregadas y corte por Otsu).	31
Figura 12. Curvas de entrenamiento de los modelos de XGBoost y LigthGBM	38
Figura 13. Matriz de confusión de XGBoost vista sobre los distintos Cut-Off’s	43
Figura 14. Matriz de confusión de XGBoost vista sobre los distintos <i>Cut-Off’s</i> (gráfico lineal)	43
Figura 15. Métricas derivadas de la matriz de confusión de XGBoost vista sobre los distintos <i>Cut-Off’s</i> (gráfico lineal)	43
Figura 16. Visualización de la curva de probabilidad calibrada y sin calibrar	46
Figura 17. Ejemplo de funcionamiento de Lime sobre una observación del dataset	48
Figura 18. Explicabilidad local con SHAP sobre ejemplo del dataset	49
Figura 19. Explicabilidad Global con SHAP sobre conjunto aleatorio del <i>dataset</i> (1)	50
Figura 20. Explicabilidad Global con SHAP sobre conjunto aleatorio del <i>dataset</i> (2)	51
Figura 21. Flujo de implementación teórica del despliegue del modelo.	54
Figura 22. Función de predicción del <i>bucket</i> de producción <i>scoring_pipeline.py</i>	55
Figura 23. Análisis bivalente. Variables categóricas “raw”	74
Figura 24. Análisis bivalente. Variables cuantitativas “raw”	76
Figura 25. Gini de las variables del conjunto de datos	78
Figura 26. IV de las variables del conjunto de datos	80
Figura 27. <i>Permutation Importance</i> de las variables del conjunto de datos	81
Figura 28. VIF de las variables cuantitativas del conjunto de datos	82
Figura 29. KS de las variables cuantitativas del conjunto de datos	83

Lista de Tablas

Tabla 1. ODS de afectación sobre el proyecto	10
Tabla 2. Flujo temporal del proyecto	14
Tabla 3. Métodos de imputación de variables cuantitativas.	26
Tabla 4. <i>Long-list</i> de variables con cada uno de los <i>tests</i> de <i>performance</i>	29
Tabla 5. <i>Short-List</i> de predictores tras el pipeline de selección.	31
Tabla 6. Resumen de características más relevantes por modelo	32
Tabla 8. Métricas finales de cada modelo sobre el conjunto de test.	38
Tabla 9. Matriz de confusión teórica de un clasificador	42
Tabla 9. Espectro de hiperparámetros considerado por modelo y valor final tras Optuna.	85

Página intencionadamente
en blanco

1. Introducció

1.1. Contexto y justificación del Trabajo

El sector asegurador enfrenta constantes desafíos en la evaluación del riesgo de siniestralidad, un aspecto crítico que influye en la rentabilidad de las aseguradoras, la tarificación de primas, la gestión del capital y el cumplimiento de regulaciones exigentes como Solvencia II. La correcta predicción de siniestros permite no solo mejorar la sostenibilidad financiera de las aseguradoras, sino también ofrecer primas más justas y adecuadas al perfil de riesgo de cada asegurado, optimizando la relación entre rentabilidad y exposición al riesgo.

En este contexto, el uso de técnicas avanzadas de *Machine Learning* y modelado estadístico se ha convertido en una herramienta clave para mejorar la precisión en la evaluación del riesgo asegurador. La abundancia de datos históricos en el sector permite el desarrollo de modelos altamente predictivos, como en el caso del *dataset Porto Seguro Safe Driver Prediction*¹, que brinda una oportunidad por su accesibilidad para explorar desde la idiosincrasia de un conjunto de datos de seguros (propensión a la siniestralidad), hasta enfoques de modelización avanzada aplicados a la predicción de siniestros.

Sin embargo, el problema de la siniestralidad presenta un reto metodológico importante debido a la naturaleza altamente desbalanceada de los datos, ya que la mayoría de los asegurados no presentan siniestros. Este desafío exige el desarrollo de modelos que no solo sean precisos, sino también explicables, auditables y alineados con normativas regulatorias, dado el alto nivel de supervisión del sector. Además, la puesta en producción de estos modelos requiere un enfoque de *MLOps*, asegurando la trazabilidad, escalabilidad y monitorización del rendimiento a lo largo del tiempo.

Dado el impacto que tiene la correcta evaluación del riesgo de siniestralidad tanto en la solidez financiera de las aseguradoras como en la protección de los asegurados y la estabilidad del sistema financiero, este estudio resulta altamente relevante desde una perspectiva tanto académica como aplicada.

¹ El conjunto de datos de Porto Seguro, se caracteriza por ser un *dataset* ofuscado en lo relativo a variables de negocio. Esto, brinda:

- Protección de la privacidad y de datos sensibles, facilitando el cumplimiento de normativas como GDPR y capacitando la compartición de datos con terceros o para desarrollo seguro.
- Pérdida de granularidad y contexto. La componente de “*expertis* del negocio”, deja de tener relevancia ante un *dataset* ofuscado, ya que no se requerirá la entendibilidad del mismo al no poder trazar *insights* sobre las variables, pasando a un segundo plano y dejando a la evidencia estadística en un primer plano para entender el conjunto de datos.

1.1.1. Motivación

Desde una perspectiva profesional, el planteamiento del trabajo resulta especialmente atractivo debido a la experiencia en el ámbito de la cuantificación del riesgo de crédito. En este punto, es conveniente citar como en el ámbito de medición del riesgo, la adopción de metodologías *ML-based* presenta, aún hoy en día, grandes retos debido al elevado grado de escrutinio regulatorio. La necesidad de garantizar interpretabilidad, robustez y cumplimiento con directrices específicas requiere plantear una lógica metodológica que sea explicable para los supervisores, lo cual plantea un balance en las entidades para equilibrar la innovación con la transparencia, ambas exigidas por los marcos regulatorios. Si bien el sector asegurador y el bancario tienen diferencias fundamentales, ambos comparten una fuerte orientación hacia la cuantificación del riesgo y el cumplimiento regulatorio, siendo sectores estrechamente ligados en términos de metodologías y siendo el riesgo de siniestralidad el “homólogo” al riesgo de crédito en una entidad aseguradora.

El análisis del riesgo en seguros introduce un cambio de perspectiva interesante, ya que, en lugar de modelizar el riesgo de impago, el enfoque está en la probabilidad de siniestralidad, lo que plantea desafíos analíticos distintos, pero igualmente relevantes desde el punto de vista de la modelización del riesgo. Este paralelismo entre ambos sectores ofrece la posibilidad de transferir conocimientos y enfoques entre el ámbito bancario y asegurador, permitiendo una visión más amplia sobre la gestión del riesgo en sectores altamente regulados.

Asimismo, el trabajo permite explorar de manera profunda la aplicabilidad de *Machine Learning* en entornos regulados, abordando no solo la capacidad predictiva de los modelos, sino también la necesidad de garantizar su explicabilidad, validación y puesta en producción eficiente. Este último punto es clave en la evolución del riesgo cuantitativo dentro del ámbito financiero, donde la implementación de modelos en producción representa uno de los mayores desafíos operativos y regulatorios.

En definitiva, este trabajo no solo tiene un alto valor científico y práctico, sino que también resulta altamente motivador al conectar dos sectores clave dentro de la gestión del riesgo financiero, explorando soluciones innovadoras que pueden aportar mejoras tanto en la precisión predictiva como en la integración de modelos en entornos aseguradores reales.

1.2. Objetivos del Trabajo

1.2.1. Objetivo principal (Hipótesis de investigación):

El objetivo principal se centra en el desarrollo de una solución predictiva basada en técnicas de modelización con *Machine Learning* para estimar la probabilidad de siniestralidad en pólizas de seguro de automóviles, asegurando su explicabilidad, como elemento más representativo de las exigencias de las principales normativas regulatorias (Solvencia II,

EIOPA IAct) en materia de seguros, y su factibilidad de despliegue en entornos productivos mediante estrategias de *MLOps*.

1.2.2. Objetivos parciales (Preguntas de investigación y pasos previos):

Fase 1: Análisis exploratorio del conjunto de datos asegurador característico como es Porto Seguro y caracterización del problema. Esto incluye:

- Comprensión de las características del riesgo de siniestralidad en el sector asegurador, estableciendo diferencias clave con la modelización de riesgo de crédito.
- Exploración y análisis el *dataset Porto Seguro Safe Driver Prediction*, detectando patrones, relaciones y sesgos en los datos.
- Identificación y tratamiento de valores atípicos, datos faltantes y problemas de calidad de datos, asegurando su preprocesamiento adecuado.
- Evaluación del grado de desbalance de clases en el *dataset* y determinar la necesidad de aplicación de técnicas adecuadas para su tratamiento (*oversampling*, *undersampling*, generación sintética de datos...).
- Selección de variables exhaustiva y relevante (*Feature Selection*) para mejorar la interpretabilidad y eficiencia del modelo, dada una entrada de datos ofuscada.

Fase 2: Desarrollo del modelo predictivo

- Contraste de diferentes soluciones metodológicas de Machine Learning supervisado a partir de los referentes de la industria basados en árboles de decisión y metodologías derivadas de estos con ensemble (*Boosting*), tales como *XGBoost* y *LightGBM*, por su relevancia en el estado del arte. Planteamiento en la exploración del uso de técnicas más innovadoras basadas en el uso de *ANN's* con mecanismos de atención sobre datos tabulares.
- Evaluación del rendimiento de los modelos mediante métricas robustas: *AUC-ROC*, *F1-Score*, *Precision-Recall Curve*. En particular, dado el desbalanceo de clases que presenta de manera natural la medición del riesgo de siniestralidad, la correcta visualización de la matriz de confusión y las métricas que se derivan de esta es esencial para entender la capacidad del clasificador.
- Optimización de la hiperparametría de cada solución analítica con la finalidad de ajustar el modelo al caso de uso específico (uso de técnicas como *Bayesian Optimization/Grid Search*, así como interfaces como Optuna que permiten una gran escalabilidad del mero ejercicio).
- Calibración de la curva de probabilidad obtenida por la mejor solución analítica, pasando de una visión “diferenciación” (ordenación del cliente) a una visión de “cuantificación” (medida de la probabilidad del evento de siniestro del cliente ajustada al caso real).
- Exploración de técnicas de *Explainable AI (XAI)*, como *SHAP* y *LIME*, para garantizar que el modelo sea interpretable y auditable.

Fase 3: Implementación y despliegue en entornos productivos (definición teórica):

Se propone de manera teórica, el procedimiento nominal que seguiría un enfoque de puesta en producción de la solución analítica para predecir el riesgo de siniestralidad, con el objetivo de desarrollar esta parte, si cabe, de manera directa en un futuro. El procedimiento cubre:

- Implementación de estrategias de *MLOps* para la gestión del modelo en producción (versionado, automatización de pipelines, monitorización de rendimiento).
- Diseño de un pipeline de inferencia eficiente, integrando el modelo en un entorno explotable para aseguradoras.

1.3. Impacto en sostenibilidad, ético-social y de diversidad

La explotación de datos ofuscados del sector asegurador y en el modelado predictivo del riesgo de siniestralidad, se enmarca sobre un entorno altamente regulado. Por ello, es necesario una integración transversal relativa a consideraciones de sostenibilidad, compromiso ético y sensibilidad hacia la diversidad en todas las fases del proyecto.

1.3.1. Impacto en sostenibilidad (ODS)

Desde la perspectiva de la sostenibilidad, se prevé una contribución indirecta del proyecto sobre los Objetivos de Desarrollo Sostenible (ODS); en particular al ODS 8 (Trabajo decente y crecimiento económico) y al ODS 9 (Industria, innovación e infraestructura), mediante la aplicación de técnicas de analítica avanzada orientadas a optimizar procesos de decisión en el ámbito asegurador. A continuación, se muestra en la siguiente tabla, los posibles ODS que se ven impactados con el presente proyecto:

ODS	Nombre	Contribución del proyecto
ODS 8	Trabajo decente y crecimiento económico	Aplicación de inteligencia artificial para optimizar la eficiencia y la toma de decisiones en el sector asegurador.
ODS 9	Industria, innovación e infraestructura	Desarrollo de modelos predictivos de analítica avanzada en entornos altamente regulados, impulsando la transformación digital del sector.
ODS 10	Reducción de las desigualdades	Vigilancia metodológica para evitar sesgos algorítmicos indirectos, pro una IA justa y no discriminatoria.
ODS 16	Paz, justicia e instituciones sólidas	Uso de datos ofuscados conforme a principios de privacidad y transparencia, alineado con el RGPD y marcos éticos de protección.

Tabla 1. ODS de afectación sobre el proyecto

1.3.2. Impacto ético-social

La aplicación de soluciones predictivas puede tener implicaciones directas sobre personas y recursos. Por ello, es necesario adoptar un enfoque prudente y ético, que brinde en todo momento consciencia situacional. El uso de datos (ya anonimizados por la mera naturaleza del *dataset*), en lugar de datos personales identificables, fomenta un tratamiento ético y legal de la información de acuerdo con principios del RGPD en lo que hace a la privacidad individual de los asegurados.

Si bien se tiene un elevado desbalanceo de clases, se desconsidera la alteración artificial de la distribución empírica de los datos (como el sobre muestreo sintético), con el objetivo

de preservar la integridad estadística del conjunto de datos y respetar la naturaleza de la información ofuscada. Esta decisión, se considera bajo un enfoque realista que en muchos contextos regulatorios es requerido. Además, el tratamiento de los datos se ajustará a los límites normativos del sector, garantizando que no se intente revertir la anonimidad ni enriquecer artificialmente las variables disponibles.

Finalmente, se establece como prioridad la adopción de modelos que permitan explotar mecanismos de explicabilidad, con el fin de asegurar la trazabilidad de las predicciones y facilitar su validación desde una doble perspectiva: técnica e regulatoria. Este principio de transparencia en la predicción algorítmica resulta clave en entornos altamente regulados, donde la confianza en los sistemas automatizados depende de su capacidad de ser comprendidos y auditados, con elevada transparencia y capacidad para ser replicados por un tercero.

1.3.3. Impacto en diversidad

Dado que el conjunto de datos utilizado se encuentra ofuscado y no contiene variables sensibles de forma explícita que puedan ser trazables y/o referidas a un asegurado, no será posible identificar ni analizar directamente sesgos relacionados con aspectos como el género, la edad o la etnia. Se mantendrá una atención metodológica para evitar que el modelo aprenda patrones que, aun de forma indirecta, puedan conducir a decisiones discriminatorias. Para ello, se evalúa la influencia relativa de las variables disponibles en las predicciones, con el objetivo de identificar posibles correlaciones espurias.

1.3.4. Riesgos del proyecto

La planificación inicial del proyecto pone sobre la mesa una serie de riesgos inherentes que deben ser gestionados a lo largo del desarrollo:

- **Riesgo de sobreajuste a patrones no generalizables**, derivado del desbalance natural de las clases. Este riesgo se aborda mediante el uso de una exhaustiva validación y métricas específicas sobre la matriz de confusión del clasificador binario.
- **Riesgo de pérdida de interpretabilidad**, especialmente al utilizar modelos no lineales. Su principal reducción, depende de las técnicas de interpretabilidad *expost* que permitan comprender el comportamiento del modelo, elemento que debe valorarse desde un inicio, sobre una preselección de modelos que dispongan de esta capacidad.
- **Riesgo ético asociado a la automatización de decisiones**, que se afronta mediante un enfoque asistencial. Como ante cualquier solución analítica basada en modelos predictivos, esta no se diseña con la finalidad de reemplazar la decisión humana, sino para complementarla, proporcionando una herramienta analítica que respalde la toma de decisiones informadas.

No obstante, debe tenerse en consideración, que el uso de datos ofuscados reduce esta capacidad de trazar criterios de negocio sobre la solución de manera

independiente, sin una relación/transformación a los datos crudos que refieran a los datos “raw” de los asegurados, nominativos y discriminantes.

1.4. Enfoque y método seguido

1.4.1. Estrategia de investigación

Este trabajo sigue una estrategia de investigación aplicada con enfoque cuantitativo, basada en el análisis de datos y la implementación de modelos de *Machine Learning* para la predicción de siniestralidad en seguros de automóviles. La investigación se enmarca en un contexto experimental, desde la entendibilidad del *dataset* hasta la exploración de diversas técnicas de modelización para identificar el enfoque óptimo.

La metodología se estructura en tres fases principales con el siguiente peso definido, que es extrapolable al tiempo de dedicación:

- Exploración y preprocesamiento de datos (50%)
- Desarrollo y validación de modelos de *Machine Learning* (40%)
- Consideraciones de *MLOps* (10%)

El análisis experimental se realiza en *Jupyter Notebooks* dentro de *VS Code*, permitiendo una integración flexible entre código, visualizaciones y documentación/*snippets* que brindan toda explicabilidad necesaria a efectos de seguimiento del caso de uso, en el propio notebook.

Este enfoque facilita la transparencia y reproducibilidad del estudio, elementos clave en un contexto académico y regulado. Para el control de versiones y la puesta en disposición del proyecto para la comunidad, se emplea *GitHub*, asegurando la trazabilidad del código y los experimentos realizados a lo largo del desarrollo del proyecto.  [Enlace a Github](#).

1.4.2. Descripción de la metodología de trabajo

Fase 1: Análisis exploratorio y preparación de datos

- Uso técnicas de exploración de datos para comprender la estructura del *dataset Porto Seguro Safe Driver Prediction*.
- Enfoque del problema del desbalanceo de clases.
- Análisis de la correlación entre variables, detección de valores atípicos, tratamiento de datos faltantes y pipeline de selección de *features*.

Herramientas - *Python* (Paquetería: Pandas, NumPy, Matplotlib, Seaborn, Scikit-learn...).

Fase 2: Modelización predictiva y evaluación

- Entrenamiento de modelos de *Machine Learning* supervisado, comparando algoritmos como *XGBoost*, *LightGBM*, *TabNet* y el enfoque clásico como es la Regresión Logística.

- Optimización de hiperparámetros para ajustar cada modelo a las necesidades de los datos.
- Aplicación de enfoques de *Explainable AI (XAI)* como *SHAP* y *LIME* para garantizar la interpretabilidad del modelo.

Herramientas - *Python* (Paquetería: Scikit-learn, XGBoost, LightGBM, Optuna, LIME, SHAP...)

Fase 3: Producción (basis)

En lugar de abordar una implementación real con herramientas de MLOps avanzadas, se ha optado por diseñar una arquitectura de despliegue teórica, alineada con buenas prácticas de ingeniería de *Machine Learning*, que permite demostrar la viabilidad técnica del sistema en un entorno productivo. Principalmente, se considerará:

- Un pipeline de inferencia centralizado para replicar el preprocesamiento del entrenamiento a partir del “.pkl” guardado tras el entrenamiento.
- Planteamiento de un sistema de API (e.g FastAPI), como *endpoint* de predicción mediante JSON y validación estructural a través de Pydantic.
- Una interfaz gráfica en Streamlit para facilitar el uso por parte de perfiles no técnicos.
- Un sistema de empaquetado con Docker, que asegura portabilidad y reproducibilidad en entornos productivos.

Herramientas: (propuesta teórica): pickle, Streamlit, FastAPI, Docker, Pydantic...

Aunque no se ha llevado a cabo un despliegue real, esta estructura permite simular con fidelidad el comportamiento del sistema en producción, garantizando trazabilidad, consistencia en las transformaciones y escalabilidad futura. El enfoque se ha centrado en sentar las bases de una arquitectura auditable, reproducible y alineada con los principios de gobernanza del dato exigidos en entornos regulados como el asegurador.

1.4.3. Justificación de la metodología

El uso de Jupyter Notebooks en VS Code permite una documentación estructurada del análisis, facilitando la explicación de los hallazgos de cada fase. GitHub aporta control de versiones, asegurando la trazabilidad del código y la gestión de cambios en los experimentos. En el marco de la propuesta teórica de despliegue, se ha diseñado una arquitectura orientada a la escalabilidad, mantenibilidad y auditabilidad del modelo.

1.4.4. Alcance de la investigación

Que **sí** se abordará, en línea con los puntos del apartado anterior:

- Evaluación de la siniestralidad en seguros de automóviles con un enfoque basado en *Machine Learning*.
- Análisis exhaustivo del *dataset Porto Seguro Safe Driver Prediction*.
- Comparación de modelos de clasificación y su aplicabilidad en entornos aseguradores.
- Estudio del impacto del desbalanceo del dato y su impacto en la modelización.

- Implementación de técnicas de explicabilidad para justificar las predicciones del modelo.
- Análisis de las implicaciones en producción, incluyendo estrategias de *MLOps*.

Que **no** se abordará:

- Modelización de riesgos aseguradores distintos a la siniestralidad (por ejemplo, mortalidad o riesgos catastróficos).
- Evaluación de siniestralidad en sectores diferentes al automovilístico.
- Modelización con datos internos de una aseguradora (se usará un *dataset* público).
- Implementación de una solución final en una empresa aseguradora real (se trabajará a nivel de prototipo académico).

1.5. Planificación del trabajo

La gestión del tiempo es esencial sobre cualquier proyecto. Por ello, este apartado pretende trasladar al lector consciencia situacional sobre los puntos clave en la organización que dan lugar a hitos representativos durante el desarrollo total del proyecto. La organización del trabajo, con el objetivo de garantizar un seguimiento eficiente del progreso, se realizará con las siguientes herramientas:

- GitHub: Versionado del código y documentación de cambios en el proyecto.
- Jupyter Notebooks (VS Code): Análisis exploratorio, modelización y evaluación.

A continuación, se traslada el cronograma de implicación seguido:

Fase	Semana	Fechas	Tareas principales	Dependencias
Análisis Exploratorio y Preprocesamiento	1-2	19 feb - 3 mar	Exploración de datos, detección de valores atípicos y datos faltantes, análisis de desbalanceo.	Ninguna
Feature Engineering y Selección de Variables	3-4	4 mar - 17 mar	Creación y selección de nuevas variables, encoding de variables categóricas.	Análisis exploratorio
Desarrollo y Evaluación de Modelos Base	5-6	18 mar - 31 mar	Entrenamiento de modelos iniciales (XGBoost, LightGBM, CatBoost), tuning básico de hiperparámetros.	Feature engineering
Optimización y Evaluación Avanzada	7	1 abr - 7 abr	Optimización avanzada de hiperparámetros, selección del mejor modelo, evaluación final.	Modelos base
Explicabilidad e Interpretabilidad del Modelo	8	8 abr - 14 abr	Aplicación de SHAP, LIME, evaluación de interpretabilidad, justificación del modelo.	Modelo final
Gestión del Modelo y MLOps Ligero	9	15 abr - 21 abr	Creación del pipeline básico para guardar y versionar el modelo, integración con MLflow.	Modelo final
Evaluación Final y Validación	10	22 abr - 28 abr	Validación con datos de test, análisis de estabilidad del modelo, preparación de gráficos.	MLOps ligero
Redacción de la Memoria	11-12	29 abr - 12 may	Elaboración del documento final, integración de resultados y hallazgos clave.	Evaluación final
Revisión y Ajustes Finales	13	13 may - 18 may	Revisión de la memoria, corrección de detalles y preparación de la entrega.	Redacción final
Entrega final de la memoria	-	18 may	Fecha clave: cierre del proyecto	Informe final listo

Tabla 2. Flujo temporal del proyecto

Asimismo, el diagrama de Gantt muestra visualmente el flujo de desarrollo de todos los puntos/hitos del proyecto hasta la entrega de la memoria:




Figura 1. Diagrama de Gantt del ciclo del proyecto.

1.6. Breve resumen de productos obtenidos

El principal entregable del trabajo será un Jupyter Notebook “.ipynb”, el cual puede ser exportado como artefacto “.html” para su facilidad en la lectura, concebido como un recurso académico y explicativo que permite comprender de forma detallada el caso de uso. El notebook incluirá tanto el análisis exploratorio completo del conjunto de datos como el desarrollo, entrenamiento y evaluación de los modelos predictivos aplicados al riesgo de siniestralidad.

Si bien el enfoque del proyecto no es productivo en sentido estricto, se contempla la generación de artefactos reutilizables, en particular archivos “.pkl” que contienen los modelos entrenados, con el objetivo de dejar trazada la posibilidad de una futura integración en entornos productivos o de automatización. En resumen:

- Un notebook documentado con el análisis integral de los datos y los modelos.
- Modelos serializados (.pkl) listos para su reutilización o despliegue.

Todo el desarrollo ha sido realizado en entorno Jupyter Notebook, garantizando reproducibilidad, trazabilidad y claridad en cada paso del proceso.

1.7. Breve descripción de otros capítulos de la memoria

A continuación, se presenta un resumen de los múltiples apartados que se pueden consultar en el apartado 3 del proyecto, que se suman y contextualizan el siguiente apartado 2 de estado del arte en materia:

- **Riesgo de siniestralidad:** Introducción al problema de negocio y la necesidad de estimar el riesgo mediante técnicas supervisadas.

- **Carga y preparación del *dataset*:** Descripción del conjunto de datos, características principales y definición del *target* binario.
- **Análisis exploratorio de datos (EDA):** Estudio estadístico del *dataset*, análisis de la distribución del *target* y correlación entre variables.
- **Preparación de datos:** Tratamiento de valores ausentes, transformación de variables y construcción de un pipeline estandarizado.
- **Modelización:** Presentación de modelos de clasificación aplicados y justificación de cada arquitectura.
- **Entrenamiento y evaluación:** Proceso de entrenamiento, selección del mejor modelo y análisis del rendimiento bajo métricas discriminativas.
- **Explicabilidad:** Técnicas de *explainable AI* aplicadas para interpretar las predicciones.
- **Producción:** Descripción de la arquitectura de despliegue basada en MLOps, diseño de una API REST y empaquetado del sistema.

2. Estado del arte

El análisis predictivo del riesgo en el ámbito asegurador plantea desafíos significativos, principalmente debido a la naturaleza desbalanceada de los datos. La baja incidencia del evento de siniestro genera distribuciones fuertemente asimétricas, hecho que produce sesgos en el entrenamiento y limita la capacidad de generalización de los modelos. Aunque la literatura evidencia el avance en técnicas como el sobre muestreo sintético para abordar esta problemática [1, 2, 3], su aplicación implica una alteración explícita de la distribución empírica. Por ello, en el presente trabajo se descarta su uso, priorizando en cambio estrategias que respeten la estructura estadística observada, mediante modelos robustos y métricas específicas que mitiguen el impacto del desbalance sin comprometer la validez inferencial.

A este reto se suma la explotación de datos ofuscados, una condición inherente a contextos regulados como el asegurador, donde si bien se garantiza la protección de la privacidad, se introduce una degradación informativa y de interpretación funcional, que puede limitar la precisión predictiva. La literatura reciente en *privacy-preserving data analysis* propone enfoques que buscan maximizar la utilidad estadística bajo restricciones de privacidad, mediante técnicas como la k-anonimidad, la privacidad diferencial o la minería de datos segura [4, 5, 6, 7], proporcionando un marco teórico sólido para trabajar en condiciones de información incompleta. No obstante, en la práctica de este trabajo se opta por un enfoque pragmático: los datos ofuscados se utilizarán de forma directa, asumiendo su estructura y semántica de acuerdo con la tipología del dato (categórico, continuo, ordinal, etc.), sin aplicar reconstrucciones ni imputaciones que puedan distorsionar su función original.

En términos metodológicos, el estado del arte en aprendizaje automático aplicado a la predicción de riesgo ha evolucionado significativamente hacia el uso de modelos no lineales capaces de capturar relaciones complejas entre variables en estructuras de datos tabulares. Entre estos, destacan de forma especial los algoritmos de *gradient boosting decision trees* (GBDT), como XGBoost o LightGBM [12, 13] que han demostrado una alta eficiencia y rendimiento en tareas de clasificación binaria y *scoring* en contextos financieros [8, 9, 10, 11]. Su éxito radica en su capacidad para optimizar funciones de pérdida específicas mediante el ensamblado secuencial de árboles “naive” [14], ajustando los errores residuales de iteraciones previas y modelando de forma efectiva interacciones no lineales, incluso en presencia de valores faltantes o codificaciones heterogéneas.

Estos modelos no solo ofrecen una robusta capacidad predictiva, sino que también se adaptan bien a entornos con estructuras de datos parciales o degradadas, como ocurre con los *datasets* ofuscados. La utilización de técnicas de *feature importance*, SHAP values y *gain-based metrics* en este tipo de modelos facilita, además, una comprensión granular del impacto relativo de cada variable, lo cual resulta fundamental en contextos regulados donde se exige trazabilidad y auditabilidad del proceso predictivo. De hecho, desde una perspectiva regulatoria, los modelos basados en *boosting* han sido aprobados para su uso en distintos marcos regulatorios de medición del riesgo, lo que ha favorecido su consolidación como

estándar. En contraste, las arquitecturas basadas en redes neuronales todavía no cuentan con esa legitimación regulatoria, suponiendo “*black boxes*” para la industria por lo que hasta la fecha no se tiene constancia de su validación formal en entornos aseguradores/financieros regulados [17, 18], lo que condiciona su uso en la práctica profesional.

Es precisamente en dicha materia, donde se cuenta con arquitecturas de *Deep Learning* específicas para datos tabulares, que pretenden superar algunas limitaciones de las redes neuronales tradicionales que históricamente no han logrado un rendimiento competitivo en este tipo de datos estructurados. Modelos como TabNet integran mecanismos de atención, regularización por máscaras o transformaciones jerárquicas que permiten capturar dependencias contextuales entre variables sin necesidad de ingeniería de características intensiva [15, 16]. Estas arquitecturas combinan la capacidad de generalización del aprendizaje profundo con una estructura más interpretable, integrando mecanismos de *feature selection* automática y explicabilidad integrada. A pesar de sus ventajas técnicas, su aplicación en escenarios sujetos a regulación sigue siendo incipiente, en gran medida por la dificultad de garantizar trazabilidad y validación externa bajo marcos regulatorios estrictos.

La continuidad en la evolución natural de la línea lógica del trabajo nos lleva, tras la exploración metodológica, a la capacidad de balancear rendimiento predictivo y transparencia, que se convierte en un criterio clave, especialmente en sectores donde las decisiones algorítmicas impactan directamente en personas o activos financieros. Por ello, la explicabilidad ha pasado de ser una característica deseable a una necesidad normativa, promoviendo el uso de herramientas como LIME, SHAP y técnicas de atención visualizables [19, 20]. Estas herramientas permiten entender las contribuciones locales y globales de las variables al resultado del modelo, facilitando tanto su validación técnica como su comunicación ante agentes de supervisión.

Finalmente, la puesta en producción de sistemas predictivos robustos requiere una visión integral que contemple precisión, explicabilidad y sostenibilidad técnica. La explicabilidad algorítmica, junto con prácticas de ingeniería orientadas a minimizar la deuda técnica, resulta esencial para garantizar soluciones reproducibles y escalables [21]. Este conjunto de dimensiones —desbalance, privacidad, modelización avanzada y producción— define el estado actual del conocimiento y justifica el marco bibliográfico adoptado en este trabajo.

A continuación, mostramos un diagrama conceptual del peso que pueden tener los puntos que se desgranán de la matización del estado del arte del actual apartado, a partir de su importancia relativa generada con las fuentes de datos que se han seleccionado detenidamente sobre las líneas:



Figura 2. Importancia relativa visual de las líneas de estado del arte del proyecto.

3. Materiales y métodos

3.1. Riesgo de siniestralidad – planteamiento de medición

La medición del riesgo es un proceso esencial en numerosos dominios como es el mundo asegurador. De manera genérica, evaluar el riesgo implica estimar la probabilidad de que ocurra un evento adverso, permitiendo a las organizaciones tomar decisiones informadas y optimizar recursos.

En nuestro caso de uso particular, el riesgo evaluado se refiere específicamente a la siniestralidad: es decir, la probabilidad de que un asegurado incurra en un siniestro en un horizonte temporal dado. Esta evaluación se plantea como un problema de clasificación binaria, donde la variable objetivo puede tomar dos posibles estados: cliente con siniestro (evento positivo, valor 1) o cliente sin siniestro (evento negativo, valor 0).

En la mayoría de los contextos aseguradores, los eventos adversos como los siniestros presentan una incidencia marcadamente inferior al volumen total de observaciones, lo que configura de forma natural un problema de clasificación desbalanceado. Este desbalance se caracteriza porque la proporción de observaciones correspondientes a la clase positiva (siniestros) es sustancialmente menor que la de la clase negativa (no siniestros), generando una asimetría crítica en la modelización y evaluación de desempeño, como ya se ha reiterado en varias ocasiones.

Desde un enfoque estadístico, la variable objetivo puede interpretarse como una variable aleatoria de tipo Bernoulli, donde cada observación individual representa un experimento con dos posibles resultados: siniestro (valor 1) con probabilidad p y no siniestro (valor 0) con probabilidad $1 - p$. Al considerar un conjunto de n observaciones independientes, la suma total de eventos positivos sigue una distribución binomial, cuya función de masa de probabilidad se expresa como:

$$P(X = k) = \binom{n}{k} p^k \cdot (1 - p)^{n-k}$$

Donde n es el número total de observaciones, k es el número de eventos positivos y p es la probabilidad de siniestro. La principal característica clave del riesgo de siniestralidad es que $p < 5\%$ en la mayoría de los casos, reflejando la naturaleza desbalanceada del problema.

La correcta caracterización y tratamiento de este desbalance es crítica para asegurar que los modelos predictivos no se vean sesgados hacia la clase mayoritaria y que la capacidad de detectar eventos positivos sea adecuada. Con este pretexto, damos paso al marco principal del trabajo.

3.2. Carga y preparación inicial del *dataset*

El primer paso fundamental de cualquier planteamiento analítico es comprender la naturaleza de los datos disponibles. Este concepto adquiere una mayor importancia cuando los datos son ofuscados y por tanto no conocemos acerca de información previa sobre el significado de las variables a nivel de negocio.

Consideramos como “ofuscados” los datos de nuestro planteamiento dado que no conocemos más allá de la tipología a nivel de estructural del dato que vamos a usar para explicar el riesgo. Esta visión sobre el conjunto de datos es extensiva a todas las fases de proyecto, ya dado este hecho no se pueden tomar consideraciones de negocio sobre ellos, pues no se dispone ni de nombres descriptivos ni de definiciones operativas para las variables. Por tanto, es esencial llevar a cabo un entendimiento básico y un correcto preprocesado. Esto engloba:

- Inferir la tipología de cada variable (si es binaria, categórica o cuantitativa), más allá de visualizar únicamente su tipología asociada en el *dataset* (float64, int64...)
- Determinar su distribución básica y potenciales patrones de comportamiento.
- Preparar adecuadamente las variables para poder obtener conocimiento relativo al objetivo.

3.2.1. Tipología de las variables

Para clasificar las variables de manera objetiva, se emplea un criterio basado en el número de niveles distintos que presenta cada atributo en el conjunto de datos, cuando la tipología de variable requiere de una mayor información para definir su tipología que la que tomamos en primer lugar por el tipo de datos que observamos al explotar el *dataset* (float64, int64...). Para estos casos, se establece un umbral de 20 niveles como criterio de separación:

- Si una variable presenta 20 o menos niveles únicos, se considera cualitativa.
- Si presenta más de 20 niveles únicos, se clasifica como cuantitativa.

Esta decisión está basada en el hecho de que las variables cualitativas suelen tener un conjunto reducido de categorías posibles, mientras que las variables cuantitativas tienden a tomar una variedad mucho más amplia de valores distintos.

La justificación de dicho umbral responde a prácticas estándar en análisis exploratorio de datos, donde se busca evitar la clasificación errónea de variables discretas de alta cardinalidad como categóricas. Umbrales en torno a 10–30 niveles son habituales en la literatura para distinguir entre variables verdaderamente categóricas y aquellas que, aunque discretas, se tratan analíticamente como continuas, tomando como *disclaimer* que tampoco tenemos contexto previo acerca de si los niveles presentan un marcado carácter ordinal.

Además, esta caracterización es esencial para la correcta aplicación de pruebas estadísticas, como se verá en el bloque de preparación. Por tanto, una clasificación precisa permite no solo entender mejor la estructura del *dataset*, sino también garantizar la validez

de los resultados estadísticos y la coherencia en las decisiones de modelado que se irán tomando a lo largo del caso de uso.

Snippet: Consideraciones específicas:

El dataset, presenta únicamente dos tipos de datos a nivel estructural: int64 y float64. A pesar de esta simplicidad, la descripción proporcionada por la fuente de datos (Kaggle) indica que las variables pueden clasificarse por sufijos:

- **_bin**: Variables binarias.
- **_cat**: Variables categóricas multinivel.
- **Otras/Sin sufijo**: Variables interpretadas como cuantitativas.

Estas categorías son deducibles de los nombres de las variables (ind, reg, calc, etc.), aunque no se dispone de una definición funcional completa. El enfoque ofuscado limita las consideraciones de negocio detalladas, pero asegura la privacidad y permite un análisis técnico neutral y a la vista de usuarios diversos (su disponibilidad para ser explotado en una fuente de datos abierta como es Kaggle).

En línea a lo especificado en este apartado, se sigue un enfoque híbrido para definir la tipología final de tratamiento de las variables interpretando los sufijos y contando los niveles únicos para asignar tipologías.

Una vez se ha decidido acerca de la tipología de variables según [i] su nombre/tipo y [ii] su número de niveles distintos en caso de que la primera no proporcione suficiente información, el resultado visual es el siguiente:




Figura 3. Distribución de los tipos de variables en el dataset, tras tratamiento.

3.3. Análisis exploratorio de datos (EDA)

El análisis exploratorio de datos (EDA) constituye una fase crítica en cualquier proyecto de ciencia de datos, ya que permite comprender la estructura subyacente del *dataset*, detectar patrones relevantes y preparar adecuadamente los datos para su posterior modelización. No obstante, la naturaleza ofuscada del *dataset* introduce una particularidad importante:

- No se dispone de información funcional explícita sobre las variables más allá de su tipología inferida. El análisis debe ser neutral y estructural, centrándose en patrones estadísticos y relacionales más que en interpretaciones de negocio específicas.
- La limitación anterior reduce el alcance interpretativo del EDA clásico, pero no invalida su importancia técnica: sigue siendo esencial para identificar relaciones, distribuciones, posibles anomalías y características de la estructura del conjunto de datos.

A continuación, se disponen de las visualizaciones que se han realizado para interpretar el conjunto tras definir la categoría de cada atributo.

3.3.1. Análisis Univariante del Target

Se realiza en primer lugar una visualización de la distribución de la variable objetivo (*target*), para observar [1] la proporción de clases positivas y negativas y [2] el grado de desbalanceo, anticipando las técnicas específicas de modelización y evaluación que serán necesarias posteriormente.

Según se muestra en el siguiente gráfico, la variable objetivo está altamente desbalanceada. Solo el 3.64% de las observaciones pertenecen a la Clase 1 (evento de riesgo de siniestralidad), mientras que el 96.36% están en la Clase 0 (no evento).




Figura 4. Distribución de la variable objetivo “target” del evento de siniestro

3.3.2. Análisis Bivariante

Dado el contexto ofuscado, se procede a realizar un análisis bivariante simplificado. Esto se limita a visualizar relaciones directas entre cada variable individual y el evento de siniestralidad (*target*), diferenciando según la naturaleza de cada una de las variables inferida en el apartado anterior. El detalle exhaustivo del análisis bivariante se encuentra detallado en el Anexo: **Análisis exploratorio de datos (EDA)**. A continuación, se introduce que se ha visualizado:

- **Variables binarias y cualitativas:**

Se analiza la distribución condicional al objetivo con histogramas que muestran la relación de frecuencias entre niveles de la variable y el *target*. Dicha visualización se traslada directamente a una primera detección de aquellas potenciales variables con poder discriminativo sobre el evento, aunque sin asignarles interpretación semántica explícita.

- **Variables cuantitativas:**

Se visualiza la distribución de los valores en función del *target*, mediante histogramas, que nos permiten visualizar una distribución más granular e interpretar el comportamiento a lo largo del rango que caracteriza a cada variable. Esta serie de

visualizaciones nos permite observar visualmente diferencias en la mediana, la dispersión o la forma de la distribución entre clases.

Asimismo, sobre las variables numéricas se genera la matriz de correlación (Pearson), visualmente representada con un *heatmap* para visualizar las interacciones, permitiendo:

- Identificar multicolinealidades potenciales entre los predictores numéricos que puedan afectar modelos lineales.
- Detectar grupos de variables redundantes.
- Ayudar en procesos posteriores de reducción de dimensionalidad o regularización.

Al no conocer el significado exacto de las variables, las correlaciones se interpretan únicamente desde un punto de vista estadístico, limitando la capacidad de interpretación causal que podría evaluarse en caso de conocer la definición de negocio de cada variable.

3.3.3. Correlación entre variables cuantitativas

La matriz de correlación que observamos a continuación de las variables numéricas de nuestro conjunto de datos, en general, muestra bajos niveles de correlación lineal (medida con Pearson), entre las variables cuantitativas consideradas, con la excepción de la pareja `ps_car_12` y `ps_car_13`, que presentan una correlación moderada (0.67). Este hecho sugiere un bajo riesgo de multicolinealidad estructural, lo cual refuerza la robustez del modelo frente a redundancias informativas. El resultado proporciona una base sólida para el uso de métricas complementarias, principalmente el *Variance Inflation Factor* (VIF) así como el Kolmogorov-Smirnov (KS) en etapas posteriores del pipeline selección de predictores, previamente al modelado.




Figura 5. *Heatmap* de la Matriz de Correlación de Pearson entre variables cuantitativas

3.4. Preparación de datos

3.4.1. Valores NA

En la fase de preparación de datos, uno de los primeros pasos fundamentales es la identificación y el tratamiento de los valores ausentes. En el conjunto de datos visualizado hasta este punto, los valores faltantes no están representados mediante NaN, sino que se están codificados explícitamente como “-1”. Esta codificación especial obliga a realizar un análisis previo para cuantificar el impacto de los datos faltantes y para definir una estrategia de tratamiento adecuada.

En el caso de variables de naturaleza cualitativa, según como se verá a continuación, se decide mantener diferenciada la categoría (valor “-1”). La justificación principal radica en el contexto del problema: al modelar el riesgo de siniestralidad, eliminar variables por la mera presencia de valores ausentes podría suponer una pérdida significativa de información predictiva. De hecho, la existencia de valores faltantes podría reflejar patrones de comportamiento subyacentes o características específicas de determinados perfiles de asegurados. Se muestra para consciencia situacional, las variables que disponen de NA's (entendiendo el NA como el valor sin valor -1), de nuestro *dataset*:



Figura 6. Visualización genérica de sensibilidad de variables con nan's.

Para su tratamiento y con el objetivo de maximizar la retención de información y evitar la introducción de sesgos innecesarios, se adopta un enfoque diferenciado basado en la naturaleza de cada variable:

Variables continuas: sobre esta tipología de variables, se decide imputar con la mediana de cada una de las distribuciones particulares de cada variable los valores sin información (eliminando los -1/NaN). Posteriormente a dicha imputación, se decide realizar un

tratamiento de normalización (transformación posterior hacia una distribución normal). Dada la necesidad de imputar los valores ausentes en variables cuantitativas sin introducir sesgos significativos, se han tenido en cuenta distintos métodos de imputación, como los que se ven en la tabla a continuación:

Método	Ventajas	Desventajas
Media	Facilidad de cálculo. Útil en distribuciones normales.	Muy sensible a outliers y a distribuciones sesgadas.
Mediana	Mayor robustez frente a outliers y asimetría; conserva representatividad central.	Puede ignorar estructura multimodal en la variable.
KNN	Aprovecha correlaciones entre variables; imputación más precisa.	Alto coste computacional; sensible al escalado y al ruido.
Interpolación temporal (ffill/bfill)	Preserva dinámica secuencial.	No aplica en datasets sin componente temporal

Tabla 3. Métodos de imputación de variables cuantitativas.

Considerando las características específicas del *dataset*: “Estructura tabular (no secuencial, no temporal), con outliers y distribuciones potencialmente asimétricas de las variables”, se decide como el más adecuado dada su robustez y simplicidad es la imputación por la mediana. Esta elección proporciona robustez frente a valores extremos y minimiza el riesgo de distorsionar la distribución original de las variables. Posteriormente, para mejorar la distribución de las variables imputadas y favorecer la aplicabilidad de modelos que suponen normalidad (como regresiones o modelos basados en distancia), se aplica un *Quantile Transformer* para transformar las variables hacia una distribución normal. Lo podemos ver:




Figura 7. Visualización del efecto de la imputación sobre las variables cuantitativas que lo requieren.

Variables cualitativas/binarias: conservación del valor “-1” como una categoría explícita. Este enfoque permite modelar la ausencia de información como una característica más, manteniendo la integridad del conjunto de datos y posibilitando que los modelos capturen

efectos derivados de la falta de información explícita. Esta estrategia global persigue un doble objetivo:

- Preservar la capacidad predictiva al evitar la eliminación de registros o variables relevantes.
- Mantener la representatividad original de los datos, respetando su estructura, sesgos y relaciones subyacentes.

3.4.2. Selección de variables

El presente proceso pretende constatar la importancia de cada variable en relación con el *target* definitorio de nuestro planteamiento de cuantificación del riesgo. El siguiente apartado entabla un análisis estructurado a partir de una batería de pruebas estadísticas que, con referencia a la industria, nos aportan consciencia situacional acerca de la relevancia de una variable sobre el *target*.

Dada la dimensionalidad inicial del *dataset* original, se plantea la necesidad de aplicar un enfoque combinado de selección de variables, basado en criterios estadísticos, tanto paramétricos como no paramétricos. Dicho enfoque se resume esquemáticamente en el siguiente flujo/pipeline, que se seguirá a lo largo de los próximos apartados:




Figura 8. Pipeline del flujo diseñado para la selección de variables con relevancia sobre el *target*

El resultado individual y los tests a nivel teórico aplicados sobre las variables del *dataset* se detallan de manera exhaustiva en el Anexo: **Selección de Variables – Cálculo de indicadores por variable**. En el presente apartado, se procede desde la visualización de la métrica agregada, la cual también incluye la visualización de las métricas individuales, así como la visualización que nos lleva a la *Short-List* final con el proceso de dicotomización.

3.4.2.1. Métrica agregada para decisión

El proceso de selección de variables cuenta con la finalidad de reducir el espacio dimensional de entrada a la solución predictiva, con el objetivo de reducir la complejidad dimensional trasladada por un *dataset* ofuscado, siempre tomando en cuenta el poder predictivo de los predictores en relación con el *target*. En línea con el proceso, se ha evaluado el Gini, el *Information Value* y la Importancia por Permutación sobre todos los predictores, así como el VIF y la prueba KS para solamente aquellos predictores continuos.

Ni el VIF ni el KS muestran evidencias que nos lleven a considerar excluir alguno de los predictores continuos de nuestro conjunto de datos. Todos poseen un VIF y un KS moderadamente bajo. En lo relativo a las métricas puramente de cuantificación de

importancia, (Gini, IV e Importancia por permutación) y su resultado, se va a proceder de manera totalmente objetiva en base a la siguiente consideración.

“Se tiene una “long-list” con todos los predictores y el objetivo es generar una short-list con los que hayan demostrado mejor performance en el proceso de selección”.

Una vez calculadas individualmente diversas métricas de capacidad predictiva sobre cada una de las variables explicativas, es necesario consolidar dicha información en una única métrica escalar que permita comparar de forma robusta el conjunto de predictores en base a las siguientes razones:

- I. Cada métrica captura aspectos complementarios del poder discriminativo de una variable: el Gini refleja asociación ordinal, el IV mide segmentación informativa, y la *Permutation Importance* estima el impacto marginal en el rendimiento de un modelo predictivo.
- II. El uso único de una métrica individual puede conducir a decisiones sesgadas, al depender de supuestos específicos o sensibilidad a la partición.

Para resolver este problema, se construyen dos métricas agregadas² con el objetivo de representar, de forma sintética y estable, la capacidad predictiva conjunta de cada variable:

- $Score_1 = |Gini| + |IV|$
- $Score_2 = |Gini| + |IV| + Permutacion\ Importance$

Con el fin de evaluar la conveniencia de incluir el tercer componente (*Permutation Importance*), se analiza la dependencia entre $Score_1$ y $Score_2$. Para ello, se modela $Score_2$ como función lineal de $Score_1$ con el objetivo de no realizar una diagnosis exhaustiva del resultado, sino que simplemente se visualiza como $Score_2$ está linealmente determinada por $Score_1$




Figura 9. Relación las métricas agregadas generadas ($Score_1$ y $Score_2$).

Este resultado implica que el valor de *Permutation Importance* no introduce información adicional relevante al proceso de ranking, dado que su contribución está capturada casi en su totalidad por la combinación del Gini y el IV. Según este grado de colinealidad, la inclusión

² En la práctica, no se han diferenciado por la nomenclatura “scores”, sino que muchas veces se han tratado con nomenclatura directa con lo que miden: $|Gini| + |IV| + Permutacion\ Importance$ o $|Gini| + |IV|$

de *Permutation Importance* es innecesaria, pudiendo inducir redundancia o amplificación espuria de ciertas variables. En consecuencia, y conforme al principio de parsimonia, se descarta $Score_2$ y se adopta $Score_1$ como métrica agregada definitiva. La métrica agregada permite ordenar de forma unívoca el conjunto de variables explicativas en función de su capacidad predictiva respecto al evento de siniestro.

La ordenación obtenida constituye la base empírica sobre la que se apoyarán las decisiones posteriores de selección o priorización de predictores. Se muestra a continuación:

Feature	Gini	Information Value (IV)	Permutation Importance	Sum Gini + IV	Sum Gini + IV + Perm
ps_car_13	0.15309	0.07207	0.10080	0.22516	0.32596
ps_car_12	0.11031	0.03995	0.05712	0.15026	0.20738
ps_reg_03	0.09806	0.03917	0.04368	0.13723	0.18091
ps_ind_06_bin	-0.08869	0.03459	0.06720	0.12328	0.19048
ps_ind_07_bin	0.07979	0.03082	0.08736	0.11061	0.19797
ps_ind_17_bin	0.06450	0.03289	0.11761	0.09739	0.21500
ps_ind_16_bin	-0.07018	0.02113	0.08400	0.09131	0.17531
ps_car_02_cat	-0.06323	0.02523	-0.00336	0.08846	0.09182
ps_car_03_cat	0.06276	0.01027	0.11425	0.07303	0.18728
ps_car_07_cat	-0.04448	0.00958	0.14449	0.05406	0.19855
ps_car_08_cat	-0.04057	0.01088	0.00336	0.05145	0.05481
ps_car_04_cat	0.00791	0.03496	0.08400	0.04287	0.12687
ps_car_14	0.02395	0.01879	0.02688	0.04274	0.06962
ps_reg_02	0.00063	0.04186	0.04032	0.04249	0.08281
ps_ind_05_cat	0.00870	0.03000	0.33265	0.03870	0.37135
ps_car_01_cat	-0.00032	0.03670	0.23521	0.03702	0.27223
ps_car_06_cat	0.00096	0.03382	0.02352	0.03478	0.05830
ps_car_05_cat	0.03309	0.00002	0.01008	0.03311	0.04319
ps_car_11_cat	0.02483	0.00639	0.09408	0.03122	0.12530
ps_car_15	0.00060	0.03006	0.01008	0.03066	0.04074
ps_ind_08_bin	0.02597	0.00466	0.05040	0.03063	0.08103
ps_ind_03	-0.00178	0.02880	0.06048	0.03058	0.09106
ps_ind_04_cat	0.02607	0.00291	0.36962	0.02898	0.39860
ps_reg_01	-0.00032	0.02400	0.05040	0.02432	0.07472
ps_car_09_cat	0.00685	0.01679	0.01680	0.02364	0.04044
ps_ind_09_bin	-0.01708	0.00200	0.02352	0.01908	0.04260
ps_car_11	-0.00440	0.01275	0.00000	0.01715	0.01715
ps_ind_15	-0.00074	0.01612	0.04032	0.01686	0.05718
ps_ind_01	0.00414	0.01177	0.00336	0.01591	0.01927
ps_ind_18_bin	0.00876	0.00058	0.00000	0.00934	0.00934
ps_ind_02_cat	0.00447	0.00108	0.23521	0.00555	0.24076
ps_ind_12_bin	0.00403	0.00147	0.00000	0.00550	0.00550
ps_calc_19_bin	-0.00444	0.00009	0.00000	0.00453	0.00453
ps_calc_10	0.00345	0.00046	0.02016	0.00391	0.02407
ps_calc_14	0.00291	0.00032	0.00336	0.00323	0.00659
ps_ind_14	0.00103	0.00146	0.00000	0.00249	0.00249
ps_calc_20_bin	-0.00206	0.00003	0.00000	0.00209	0.00209
ps_calc_16_bin	0.00161	0.00001	0.00000	0.00162	0.00162
ps_calc_11	-0.00000	0.00139	0.02352	0.00139	0.02491
ps_calc_18_bin	0.00133	0.00001	0.01344	0.00134	0.01478
ps_calc_02	0.00047	0.00049	0.01344	0.00096	0.01440
ps_calc_06	0.00000	0.00095	0.02688	0.00095	0.02783
ps_calc_15_bin	-0.00086	0.00001	0.00000	0.00087	0.00087
ps_calc_03	0.00044	0.00036	0.01008	0.00080	0.01088
ps_calc_12	-0.00021	0.00058	0.00672	0.00079	0.00751
ps_calc_01	0.00010	0.00068	0.00672	0.00078	0.00750
ps_ind_13_bin	0.00040	0.00015	0.00000	0.00055	0.00055
ps_ind_11_bin	0.00044	0.00010	0.00000	0.00054	0.00054
ps_calc_07	0.00001	0.00051	0.01344	0.00052	0.01396
ps_calc_17_bin	-0.00045	0.00000	0.00672	0.00045	0.00717
ps_calc_08	0.00000	0.00041	0.01344	0.00041	0.01385
ps_calc_05	0.00012	0.00029	0.00000	0.00041	0.00041
ps_calc_09	-0.00008	0.00030	0.00000	0.00038	0.00038
ps_calc_13	-0.00011	0.00025	0.02016	0.00036	0.02052
ps_calc_04	0.00016	0.00015	0.00000	0.00031	0.00031
ps_car_10_cat	0.00024	0.00003	0.00000	0.00027	0.00027
ps_ind_10_bin	0.00019	0.00008	0.00000	0.00027	0.00027

Tabla 4. Long-list de variables con cada uno de los tests de performance

3.4.2.2. *Dicotomización del ranking mediante Otsu*

Una vez calculada la métrica agregada $Score_1$ sobre cada variable y ordenado el conjunto de predictores en función de dicho valor, se procede a definir un umbral de corte que permita distinguir de forma empírica entre variables con alto y bajo poder predictivo. Esta partición binaria resulta útil para reducir dimensionalidad y seleccionar un subconjunto de predictores relevantes, sin recurrir a criterios expertos o valores arbitrarios.

Para ello, se aplica el algoritmo de Otsu, un método clásico de dicotomización ampliamente utilizado en contextos de segmentación. El algoritmo busca un valor umbral t^* que maximiza la varianza intercalase cuando un conjunto escalar es particionado en dos grupos.

- Formalmente, se busca el umbral t^* que maximiza: $t^* = \operatorname{argmax} \sigma_b^2(t)$
- Donde la varianza intercalase es: $\sigma_b^2(t) = \omega_0(t)\omega_1(t)(\mu_0(t) - \mu_1(t))^2$

Con $\omega_0(t)$ como la proporción de variables con métrica $< t$, $\omega_1(t)$ la proporción de variables con métrica $\geq t$, $\mu_0(t)$ la media de las métricas en grupo 0 y $\mu_1(t)$ la media de las métricas en grupo 1.

Aplicado a la distribución de $Score_1$ sobre el conjunto de variables, el algoritmo permite identificar de forma no supervisada un punto de corte óptimo que maximiza la separación entre las medias de los dos grupos generados. Este umbral se interpreta como el valor que distingue variables con capacidad predictiva claramente superior de aquellas con contribución más limitada. Este procedimiento tiene varias ventajas:

- **Objetividad:** evita la necesidad de establecer un umbral manual o empírico.
- **Escalabilidad:** puede aplicarse a cualquier número de variables.
- **Consistencia:** se basa únicamente en la estructura de la distribución de la métrica $Score_1$

El resultado del algoritmo de Otsu permite así obtener un subconjunto reducido de predictores, seleccionados en base a un criterio de maximización de varianza *inter-grupo* sobre la métrica agregada $Score_1$, garantizando que las variables retenidas presentan de forma conjunta un comportamiento significativamente diferente del resto en capacidad discriminativa frente al *target*:




Figura 10. Visualización del umbral de Otsu sobre Sum Gini + IV




Figura 11. Visualización final de predictores (métricas agregadas y corte por Otsu).

El conjunto final de predictores, aquellos con $\text{Score} \geq \text{umbral_otsu}$, es el siguiente:

Feature	Gini	Information Value (IV)	Permutation Importance	Sum Gini + IV	Sum Gini + IV + Perm
ps_car_13	0.15309	0.07207	0.10080	0.22516	0.32596
ps_car_12	0.11031	0.03995	0.05712	0.15026	0.20738
ps_reg_03	0.09806	0.03917	0.04368	0.13723	0.18091
ps_ind_06_bin	-0.08869	0.03459	0.06720	0.12328	0.19048
ps_ind_07_bin	0.07979	0.03082	0.08736	0.11061	0.19797
ps_ind_17_bin	0.06450	0.03289	0.11761	0.09739	0.21500
ps_ind_16_bin	-0.07018	0.02113	0.08400	0.09131	0.17531
ps_car_02_cat	-0.06323	0.02523	-0.00336	0.08846	0.09182
ps_car_03_cat	0.06276	0.01027	0.11425	0.07303	0.18728
ps_car_07_cat	-0.04448	0.00958	0.14449	0.05406	0.19855
ps_car_08_cat	-0.04057	0.01088	0.00336	0.05145	0.05481
ps_car_04_cat	0.00791	0.03496	0.08400	0.04287	0.12687
ps_car_14	0.02395	0.01879	0.02688	0.04274	0.06962
ps_reg_02	0.00063	0.04186	0.04032	0.04249	0.08281

Tabla 5. Short-List de predictores tras el pipeline de selección.

3.5. Modelización

La siniestralidad, definida como la probabilidad condicional de que un contrato de seguro u operación financiera incurra en pérdidas, puede modelizarse como un problema de clasificación binaria. Sea $Y_i \in \{0,1\}$ la variable indicadora de siniestro, donde $Y = 1$ representa la ocurrencia del evento adverso. Se considera un conjunto de predictores $X_i, \in \mathbb{R}$ sobre los cuales se construyen estimadores de $P(Y = 1|X)$ mediante diferentes paradigmas de aprendizaje supervisado.

Una vez tenemos a nuestra disposición un subconjunto robusto de predictores mediante el proceso selectivo del apartado anterior, se procede a la construcción y evaluación de modelos supervisados para la predicción del evento de siniestralidad. Para ello, se han seleccionado cuatro algoritmos de referencia siguiendo la línea lógica del proyecto explicitada en función del Estado del Arte **¡Error! No se encuentra el origen de la referencia.:**

- Regresión Logística (*baseline*)
- XGBoost
- LightGBM
- TabNet

Representando distintas familias de modelización: modelos lineales generalizados, métodos de ensamblado con *boosting*, y redes neuronales especializadas en datos tabulares. La selección de estos modelos responde a una doble motivación:

- (1) robustez empírica, y
- (2) relevancia práctica en la industria y entornos regulatorios.

Se muestra una tabla resumen de [i] los modelos que serán expuesto en el presente apartado y [ii], de su principal idiosincrasia que se irá abordando en varios aspectos a lo largo de los apartados:

Modelo	Regresión Logística	XGBoost	LightGBM	TabNet
Tipo	Modelo lineal	Ensemble de árboles	Ensemble optimizado	Red neuronal atencional
Regularización	L1, L2	L1, L2 + complejidad de árbol	L1, L2 + sampling, bundling	Entropía + sparsity
Interpretabilidad	Alta	Media (SHAP)	Media	Alta (máscaras por variable)
Escalabilidad	Alta	Alta	Muy alta	Baja-media
Estructura no lineal	No	Sí	Sí	Sí (aprendida vía atención)
Aceptación regulatoria	Muy alta	Alta (si bien documentado)	Alta (similar a XGBoost)	Baja (requiere validación específica)
Recomendado en contextos	Scoring, riesgo regulado	Fraude, chum, predicción PD	Big data bancario y asegurador	Pricing complejo, machine learning avanzado

Tabla 6. Resumen de características más relevantes por modelo

3.5.1. Regresión Logística

La Regresión Logística es un modelo lineal ampliamente utilizado para resolver problemas de clasificación binaria, particularmente en dominios donde se requiere interpretabilidad y

robustez estadística, como el riesgo crediticio y asegurador. Su estructura matemática se basa en modelar la probabilidad de ocurrencia de un evento (por ejemplo, la ocurrencia de un siniestro) como una función logística de una combinación lineal de predictores.

Formalmente, se estima la probabilidad de la clase positiva (siniestro) mediante la función sigmoide:

$$P(Y = 1|X) = \frac{1}{1 + \text{EXP}(-X^t\beta)}$$

Donde β es el vector de parámetros y $X^t\beta$ representa la función lineal sobre los predictores. La expresión convierte una combinación lineal de variables en un valor entre 0 y 1, interpretable como una probabilidad. El ajuste de los coeficientes β_j se realiza mediante máxima verosimilitud, lo que garantiza propiedades estadísticas deseables bajo supuestos adecuados (independencia, linealidad del log-odds, homocedasticidad del error en el espacio transformado, etc.).

La regresión logística es el estándar de facto en modelización de riesgo regulado, ya que sus coeficientes permiten cuantificar directamente el impacto marginal de cada variable sobre la probabilidad del evento de interés. Esta propiedad es crítica en entornos aseguradores, donde los modelos deben seguir con tales consideraciones de ser no solo predictivos, sino también transparentes, auditables y explicables ante reguladores o partes interesadas no técnicas.

A pesar de su simplicidad, su rendimiento suele ser competitivo en problemas bien estructurados, especialmente cuando las relaciones entre variables y el objetivo son predominantemente lineales o cuando se realiza un preprocesamiento adecuado. Además, su implementación es eficiente, escalable y naturalmente compatible con técnicas de regularización (L1, L2), lo que la convierte en una herramienta versátil tanto en entornos exploratorios como productivos.

3.5.2. XGBoost

XGBoost es un sistema de *boosting* de gradiente altamente eficiente, optimizado y portable, diseñado para resolver problemas de predicción con gran precisión y velocidad. Se basa en el principio de combinar múltiples aprendices débiles (árboles de regresión tipo CART) en un modelo fuerte mediante un enfoque aditivo iterativo. Una de sus principales fortalezas radica en la optimización de una función objetivo regularizada, que penaliza la complejidad del modelo para reducir el riesgo de sobreajuste.

El algoritmo emplea una aproximación de segundo orden (mediante expansión de Taylor) para actualizar sus predictores, lo que permite una construcción más eficiente y precisa de los árboles, así como una asignación óptima de los pesos en sus hojas. Entre sus capacidades destacadas se incluyen el soporte para funciones de pérdida personalizadas, la gestión interna de valores ausentes y la posibilidad de paralelizar procesos de

entrenamiento, lo que lo convierte en una herramienta clave en competiciones de ciencia de datos y aplicaciones industriales a gran escala.

3.5.3. LightGBM

LightGBM es un *framework* de *boosting* de gradiente desarrollado por Microsoft Research, diseñado específicamente para ser altamente escalable y eficiente en escenarios de datos de gran volumen y alta dimensionalidad. A diferencia de otros métodos tradicionales de *boosting*, LightGBM introduce innovaciones técnicas clave que mejoran sustancialmente su rendimiento computacional sin sacrificar precisión.

Entre sus principales innovaciones se encuentran el *Gradient-based One-Side Sampling* (GOSS), que prioriza instancias con grandes gradientes para acelerar el entrenamiento, y el *Exclusive Feature Bundling* (EFB), que agrupa variables mutuamente excluyentes para reducir la dimensionalidad. Su crecimiento de árboles sigue una estrategia *leaf-wise* con profundidad limitada, lo que permite construir árboles más profundos y específicos allí donde la ganancia informativa es mayor. Además, su algoritmo basado en histogramas mejora la eficiencia de memoria y reduce el coste computacional, posicionándolo como una de las herramientas más competitivas para aprendizaje supervisado en producción.

3.5.4. TabNet

TabNet, desarrollado por Google Cloud AI, es un modelo basado en redes neuronales diseñado específicamente para datos tabulares, ofreciendo una alternativa diferenciada a los modelos de árboles tradicionales. Su arquitectura se basa en un mecanismo secuencial de atención, donde en cada paso del modelo se seleccionan dinámicamente las variables más relevantes mediante máscaras atencionales. Esta selección se realiza de forma controlada y diferenciable, permitiendo que el modelo aprenda qué y cuándo mirar durante el procesamiento de cada observación.

TabNet integra dos bloques principales: el *Attentive Transformer*, encargado de la selección de características, y el *Feature Transformer*, que transforma las variables seleccionadas en representaciones latentes útiles para la tarea de predicción. Este proceso se repite a través de múltiples pasos (definidos por hiperparámetros), lo que permite al modelo capturar relaciones jerárquicas y no lineales complejas, aunque a un coste computacionalmente hablando elevado.

El modelo incorpora mecanismos de regularización como la *sparsity constraint* (basada en la entropía de las máscaras de atención) y la reutilización de características, lo cual favorece la generalización y evita sobreajuste. A diferencia de otros modelos de redes profundas, TabNet ofrece tanto interpretabilidad local como global, al permitir visualizar las contribuciones específicas de cada variable a cada predicción y también su importancia agregada a nivel del *dataset* completo.

3.5.5. Selección de hiperparámetros

Una vez descritos los modelos candidatos, resulta imprescindible abordar el proceso de ajuste fino de hiperparámetros, que constituye una de las fases más determinantes para alcanzar un rendimiento óptimo y generalizable en tareas de clasificación, especialmente cuando el fenómeno de interés —en este caso, la siniestralidad— presenta esa distribución fuertemente desbalanceada.

El desbalance natural del *target* introduce desafíos específicos tanto en la evaluación como en la calibración de modelos, ya que muchas métricas estándar —como la exactitud (*accuracy*), pueden inducir resultados sesgados si no se adaptan al contexto. La métrica de evaluación adoptada para la búsqueda de hiperparámetros es el AUC (Área bajo la curva ROC) sobre el conjunto de validación, que responde a criterios de robustez y generalidad:

- El AUC proporciona una medida del poder discriminativo del modelo, es decir, su capacidad para asignar mayores probabilidades a las observaciones positivas que a las negativas.
- No depende de un umbral de decisión particular, lo que lo hace útil como métrica de optimización antes de aplicar cualquier política de corte.

Sin embargo, es importante señalar que:

- El AUC no tiene en cuenta la distribución de probabilidades generadas ni penaliza la calibración incorrecta.
- No incorpora explícitamente el coste de errores tipo I y II, que puede ser relevante en problemas asimétricos como el riesgo de siniestralidad.
- En presencia de desbalance severo, puede ser conveniente considerar también otras métricas complementarias para la evaluación final del modelo, aunque no como criterio de optimización.

Por ello, la elección del AUC debe interpretarse como una estrategia técnica pragmática, orientada a evaluar la capacidad ordinal del modelo, pero acompañada de ajustes específicos en el diseño de los modelos para tratar el desbalance estructural del problema. En particular, cada modelo incluye hiperparámetros específicos relacionados con la ponderación o balance de las clases (e.g., `scale_pos_weight`, `class_weight`, `pos_weight`), según se verá a continuación.

3.5.5.1. Naturaleza y rol de los hiperparámetros en los modelos considerados

Los hiperparámetros determinan la configuración estructural y de aprendizaje de los modelos, afectando directamente su capacidad de generalización, su tendencia al *overfitting*, la estabilidad del entrenamiento y la eficiencia computacional. A diferencia de los parámetros con capacidad de ser entrenados (e.g., pesos en regresión logística o valores en hojas de árboles), los hiperparámetros no se estiman a partir de los datos en el entrenamiento, sino que deben definirse exógenamente.

Cada modelo involucra un conjunto de hiperparámetros idiosincráticos. Generalmente:

- En regresión logística, afectan la regularización (L1/L2) y el algoritmo de optimización.
- En XGBoost y LightGBM, los hiperparámetros controlan la estructura de los árboles (profundidad, número de hojas), el aprendizaje (tasa de aprendizaje, subsampling), y la regularización (penalizaciones L1/L2, número mínimo de datos por hoja, etc.).
- En TabNet, definen la arquitectura de la red (número de pasos de decisión, ancho de capas, tamaño de *embeddings*), el mecanismo de atención (coeficientes de *sparsity*) y el régimen de entrenamiento.

Dada la complejidad y la alta dimensionalidad de este espacio, es inviable explorarlo de forma exhaustiva o manual, lo que motiva el uso de técnicas de optimización automatizada.

3.5.5.2. Optuna como herramienta de optimización automática de hiperparámetros

Optuna es una paquetería de optimización automática basada en estrategias de búsqueda adaptativa. A diferencia de métodos clásicos como *grid search* o búsqueda aleatoria, que exploran el espacio de hiperparámetros sin considerar el rendimiento previo, Optuna emplea una lógica bayesiana eficiente y dinámica para concentrar la búsqueda en las regiones más prometedoras del espacio. El Anexo **OPTUNA - detalle**: presenta un mayor detalle para la interpretación del su funcionamiento interno, así como el espectro de hiperparámetros considerado sobre cada modelo y el valor final tras el proceso de optimización.

3.5.6. Preparación del conjunto de datos para entrenamiento

Antes de proceder al entrenamiento y validación de los modelos, se lleva a cabo un proceso sistemático de preparación del conjunto de datos. Este incluye la partición en subconjuntos disjuntos, el tratamiento de variables faltantes y categóricas, así como la verificación del balance de clases en cada conjunto resultante.

3.5.6.1. División en subconjuntos: entrenamiento, validación y test

El conjunto de datos se divide en tres particiones no solapadas, mutuamente excluyentes y balanceadas, con el fin de estructurar adecuadamente el flujo experimental:

- **Conjunto de entrenamiento:** utilizado para el ajuste de los modelos.
- **Conjunto de validación:** utilizado para la selección de hiperparámetros y para controlar el riesgo de sobreajuste (a partir del conjunto de entrenamiento).
- **Conjunto de test:** reservado exclusivamente para la evaluación final de los modelos, sin intervención previa.

Procedimiento:

1. Se particiona con el 80% para entrenamiento/validación, y el 20% como test.
2. Se utiliza estratificación por clase para mantener la proporción entre observaciones positivas (sinistro) y negativas (no sinistro) en cada subconjunto.
3. El conjunto de entrenamiento/validación se divide nuevamente en:
80%: conjunto de entrenamiento final

20%: conjunto de validación

3.5.6.2. *Preprocesamiento de variables para modelizar*

Se aplica un pipeline de transformación de los datos acorde a la naturaleza de cada tipo de variable, con el objetivo de garantizar su compatibilidad con los algoritmos utilizados y mejorar la estabilidad numérica de los modelos. En este punto ya disponemos de un conjunto libre de NA's pues se han tratado/imputado anteriormente.

Codificación de variables categóricas:

- Las variables categóricas nominales se transforman mediante codificación One-Hot (OneHotEncoder), generando un vector binario por cada categoría observada.
- Esta transformación permite aplicar modelos basados en distancia (regresión logística) y en estructuras numéricas (árboles, redes) sin introducir ordenaciones artificiales.

Tratamiento de variables binarias y continuas

- **Variables binarias:** se mantienen sin transformación adicional.
- **Variables continuas:** ya se encuentran escaladas previamente (normalización), por lo que se utilizan directamente en su forma actual.

Las transformaciones anteriores se integran en un único *dataset* procesado por concatenación horizontal de las variables transformadas. El resultado es una matriz numérica completa, sin valores ausentes, directamente utilizable por los modelos.

3.6. Entrenamiento y Evaluación

3.6.1. Proceso de entrenamiento

Una vez seleccionados los hiperparámetros óptimos para cada modelo mediante el *framework* Optuna, se procede al entrenamiento nominal de los cuatro algoritmos considerados: regresión logística, XGBoost, LightGBM y TabNet. Cada modelo se entrena sobre el conjunto de entrenamiento y se valida de forma continua sobre el conjunto de validación, utilizando el AUC como métrica principal de evaluación. La implementación del entrenamiento permite:

- establecer de forma explícita los hiperparámetros ajustados en la etapa de optimización,
- controlar parámetros adicionales relacionados con el desbalance de clases (e.g., `scale_pos_weight` en XGBoost y LightGBM),
- registrar de forma estructurada la evolución del rendimiento por iteración.

Por cada modelo, se generan dos artefactos que son aprovisionados con la información de su entrenamiento:

- **modelos[·]:** diccionario que contiene las instancias entrenadas de cada modelo, ya parametrizadas y listas para inferencia y evaluación en test.

- **curvas[.]:** estructura auxiliar que almacena, por modelo, los valores de AUC (y otras métricas si están disponibles) obtenidos en entrenamiento y validación durante cada iteración o época.

El proceso de entrenamiento permite:

1. Obtener para cada modelo un registro completo y trazable de sus iteraciones.
2. Comparar visualmente la evolución del rendimiento durante el proceso, tal y como observamos para el entrenamiento de los modelos de ensemble:




Figura 12. Curvas de entrenamiento de los modelos de XGBoost y LigthGBM

3. Una vez finalizado el entrenamiento, la obtención de las métricas diferenciadas para cada modelo nos permite evaluar y contrastar las soluciones entre sí. El resultado del proceso de entrenamiento con los mejores hiperparámetros es el siguiente:

Modelo	AUC		Métricas matriz de conf a un umbral				Coste Comp. relativo 0-10
	ROC	PR	Recall	F1-Score	Precision	Accuracy	
XGBoost	61,2%	5,7%	55,5%	9,1%	5,0%	59,8%	≈ 1
Reg. Logist	61,1%	5,6%	54,7%	9,2%	5,0%	60,7%	≈ 0
LigthGBM	61,1%	5,7%	55,8%	9,3%	5,1%	60,2%	≈ 1
Tabnet	58,4%	4,9%	0,0%	0,1%	14,3%	96,4%	≈ 10

Tabla 7. Métricas finales de cada modelo sobre el conjunto de test.

Para interpretar correctamente las métricas de cada modelo, se incluye un anexo detallado para este fin: **Proceso de entrenamiento – Interpretación de resultados**, por la relevancia de las métricas agregadas y matriz de confusión idiosincráticas de un caso de clasificación desbalanceado.

3.6.2. Mejor modelo

El objetivo principal de este estudio es modelizar la ocurrencia del evento de siniestro, es decir, estimar de forma probabilística el riesgo de que un cliente o póliza incurra en pérdidas significativas. Se trata de un evento crítico y poco frecuente, según se ha expresado a lo largo del trabajo, lo que genera un contexto altamente desbalanceado que exige especial atención tanto en la construcción, evaluación y selección del modelo que más se ajuste a nuestro planteamiento analítico. A continuación, se resume el contenido del proceso de entrenamiento que da lugar a las métricas sobre test de la tabla anterior y se define el “mejor modelo”.

3.6.2.1. Modelos basados en árboles de decisión ensamblados (XGBoost y LightGBM)

Los modelos de *boosting* de árboles, concretamente XGBoost y LightGBM, muestran un comportamiento consistente y aparentemente, presentan competencia en todos los indicadores relevantes (a nivel relativo entre los modelos considerados para resolver el planteamiento). Ambos alcanzan un ROC-AUC superior a 0.61, lo que evidencia una capacidad discriminativa adecuada a lo largo del rango completo de umbrales de decisión.

En cuanto a la métrica PR-AUC, ambos modelos presentan valores por encima del 5%. Dado que la tasa base de siniestralidad es del 4%, esta métrica refleja una capacidad real de capturar correctamente la clase positiva por encima de lo que se obtendría por azar.

Además, métricas umbral-dependientes como *recall* y F1-score resultan clave para evaluar el comportamiento operativo del modelo. El *recall* observado, de magnitud moderada, asegura una baja tasa de falsos negativos, lo que es esencial en contextos de riesgo donde la omisión de un siniestro podría tener consecuencias económicas graves. El F1-score, por su parte, confirma que dicha sensibilidad no se obtiene a costa de una precisión irrealista, denotando una solución equilibrada en la predicción de la clase minoritaria.

Desde un punto de vista estructural, ambos modelos aprovechan su arquitectura basada en conjuntos aditivos de árboles de decisión, capaces de capturar interacciones no lineales y efectos complejos entre predictores. Esta propiedad resulta especialmente útil en contextos aseguradores, donde los efectos cruzados entre atributos demográficos, financieros y contractuales pueden ser relevantes, pero no triviales.

3.6.2.2. Regresión logística

La regresión logística, modelo ampliamente adoptado en la predicción del riesgo por su trazabilidad estadística y facilidad de interpretación (siendo el *baseline* del planteamiento), muestra un rendimiento muy cercano al de los modelos ensemble. Aunque su estructura lineal limita la capacidad para capturar relaciones no lineales, el resultado obtenido (ROC-AUC ≈ 0.6114) confirma su viabilidad operativa como modelo de referencia, particularmente en escenarios donde la explicabilidad prima sobre la complejidad. Su adecuación práctica,

su estabilidad y su bajo coste computacional lo mantienen como una solución robusta, eficaz y conforme a las exigencias regulatorias más estrictas.

3.6.2.3. *TabNet*

Aunque TabNet propone una arquitectura innovadora basada en mecanismos de atención secuencial y representación jerárquica, su comportamiento en este problema ha sido claramente subóptimo. A pesar de registrar un *accuracy* de 96.35%, este valor es engañoso. El modelo predice casi exclusivamente la clase mayoritaria (no siniestro), como lo evidencia su *recall* prácticamente nulo y un F1-score que sigue la misma consideración, sobre umbral “óptimo que considera”.

Tanto el ROC-AUC (≈ 0.5841) como el PR-AUC (< 0.05) se sitúan por debajo de los obtenidos por cualquier otro modelo considerado. Este peor rendimiento persiste incluso tras la calibración de hiperparámetros estructurales como *n_steps*, *lambda_sparse* y *virtual_batch_size*.

A esto se le debe sumar el gran coste computacional que ha conllevado su entrenamiento según su arquitectura de redes neuronales. No obstante, dicho coste es muy elevado para considerarlo como una buena solución al planteamiento, lo que refuerza la conclusión de no considerar dicho modelo al no aportar ventajas diferenciales frente a alternativas más consolidadas y eficientes.

Con base en el análisis cuantitativo de métricas discriminativas y operativas, así como en la interpretación cualitativa de su estructura interna, se concluye que el modelo más adecuado para el problema de predicción de siniestralidad es XGBoost. Este modelo alcanza en términos relativos el mejor balance entre sensibilidad, precisión y estabilidad y será adoptado como base para los análisis posteriores.

3.6.2.4. *Reflexión final sobre los resultados obtenidos y limitaciones del modelado supervisado*

Aunque el modelo XGBoost ha sido identificado como la solución más eficaz dentro del conjunto de algoritmos evaluados, es importante reconocer que el rendimiento global, medido a través del AUC, se mantiene en valores modestos (≈ 0.6117). Esta cifra, si bien suficiente para establecer una capacidad discriminativa superior al azar, no refleja una separación tajante entre las clases ni un nivel de predictibilidad plenamente satisfactorio desde un punto de vista operativo.

Este resultado debe interpretarse en el contexto de una problemática caracterizada por dos grandes dificultades:

- **Alta asimetría en la distribución de clases:** la ocurrencia de siniestros representa un evento de baja frecuencia ($\sim 4\%$), lo que complica inherentemente su detección y penaliza las métricas umbral-dependientes como la precisión o el F1-score.

- **Limitación estructural del espacio de representación:** a pesar del uso de algoritmos avanzados y de la optimización rigurosa de sus hiperparámetros, los modelos muestran una capacidad limitada para aprender una frontera efectiva de separación. Esta limitación no se debe atribuir exclusivamente a la implementación técnica del modelo, sino a la pobreza/limitación informacional del conjunto de predictores disponibles a pesar de haber seleccionado aquellos de mayor relevancia sobre el *target* en un pipeline exhaustivo de selección.

Para mitigar y/o reducir el efecto del desbalanceo de clases, a lo largo del proceso se han incorporado estrategias para mitigarlo, que incluyen:

- Ponderación de clases (`class_weight='balanced'`), sobre los modelos que permiten diferenciarlo.
- Ajuste de `scale_pos_weight` en *boosting*.
- Funciones de pérdida adaptadas en TabNet y LightGBM.

Sin embargo, ninguna de estas técnicas ha sido suficiente para mejorar sustancialmente el rendimiento en la clase minoritaria, lo que refuerza la hipótesis de que el problema es informacional. Este fenómeno es bien conocido en la literatura:

“en ausencia de variables verdaderamente explicativas, incluso modelos más sofisticados se ven limitados por el principio de "garbage in, garbage out".

La precisión predictiva no depende exclusivamente de la complejidad del modelo, sino de la calidad y relevancia del espacio de representación que este puede explotar. En consecuencia, se identifica como principal prioridad para un futuro desarrollo del caso de uso la expansión del espacio de predictores, tanto en profundidad (calidad del dato) como en diversidad (naturaleza del dato). En particular:

- Incorporación de series temporales de comportamiento financiero para capturar dinámica y estacionalidad.
- La inclusión de variables contextuales, macroeconómicas o transversales, que enriquezcan el marco explicativo.
- El empleo de técnicas de representación densa (e.g., *autoencoders*, *embeddings* categóricos) para descubrir estructuras latentes de naturaleza no lineal.
- La exploración de enfoques causales o contrastivos, que permitan diferenciar correlaciones espurias de dependencias estructurales reales.

En resumen, se destaca que el trabajo realizado demuestra que un diseño riguroso del flujo de modelización (con control estricto de validación, calibración y evaluación cruzada), es necesario, pero no suficiente para garantizar una solución predictiva adecuada. La limitación principal recae en la señal contenida en los datos, no en la técnica de aprendizaje utilizada. Por ello, la mejora sustancial del rendimiento no vendrá necesariamente en adoptar modelos más complejos ni ajustando los ya considerados en el caso de uso existente, sino de una mejor comprensión y enriquecimiento del fenómeno que se desea modelizar.

3.6.2.5. Diagnóstico umbral-dependiente del clasificador: análisis de la matriz de confusión del mejor modelo

Para comprender el comportamiento operativo del mejor modelo seleccionado según las métricas AUC como principal componente (XGBoost), se analiza su matriz de confusión bajo distintos valores de umbral de decisión (*cut-off*), permitiendo visualizar la degradación de las predicciones en función del criterio de clasificación adoptado.

	0 (Predicho)	1 (Predicho)
0 (Real)	TN	FP
1 (Real)	FN	TP

Tabla 8. Matriz de confusión teórica de un clasificador

TP (True Positives) son siniestros correctamente identificados, **FP (False Positives)** son los casos sin siniestro clasificados erróneamente como positivos, **FN (False Negatives)** con los siniestros no detectados por el modelo y **TN (True Negatives)** son casos sin siniestro correctamente clasificados.

La evaluación de esta matriz en función de distintos umbrales resulta clave para:

- Ajustar el modelo a criterios de negocio específicos,
- Determinar el equilibrio entre sensibilidad (*recall*) y especificidad (*precision*),
- Visualizar la degradación progresiva de los cuadrantes al modificar el *cut-off*. Esto se refiere al pase de TP a FN y/o de FP a TN, en función del umbral.

Consideraciones específicas:

El objetivo principal en el contexto de siniestralidad es maximizar el número de TP, es decir, detectar con la mayor precisión posible los siniestros reales. En términos operativos, ello se traduce en maximizar el *recall* y minimizar los FN, ya que cada caso FN representa una oportunidad fallida de activar mecanismos preventivos o de cobertura sobre clientes que efectivamente presentan riesgo.

No obstante, la precisión global (*accuracy*) también debe mantenerse en niveles razonables, para no comprometer la fiabilidad del sistema. Para ello:

- Se requiere una proporción elevada de TN, evitando una degradación del modelo hacia una tasa excesiva de falsos positivos.
- El volumen de FP debe ser controlado, pues si se dispara, impactaría negativamente en la precisión y en la carga operativa del sistema, al identificar erróneamente como siniestrados a clientes que no lo son.

Este compromiso entre *recall* (sensitividad) y precisión (especificidad) es esencial en problemas donde la clase positiva es escasa pero crítica, como ocurre en la predicción de siniestralidad.

Con ese contexto, se ha implementado una exploración sistemática de la matriz de confusión para valores de umbral entre 0 y 1, evaluando la evolución de los cuadrantes en función del *cut-off*. Esta visualización permite identificar zonas de estabilidad operativa y ayuda a tomar decisiones informadas desde el punto de vista del negocio bajo distintos criterios de decisión y facilita el diseño de estrategias basadas en riesgo ajustado al perfil del cliente.




Figura 13. Matriz de confusión de XGBoost vista sobre los distintos Cut-Off's




Figura 14. Matriz de confusión de XGBoost vista sobre los distintos *Cut-Off's* (gráfico lineal)




Figura 15. Métricas derivadas de la matriz de confusión de XGBoost vista sobre los distintos *Cut-Off's* (gráfico lineal)

Del análisis gráfico se desprende como para valores de *cut-off* entre 0.40 y 0.50, se consigue un equilibrio razonable entre:

- Una tasa aceptable de TP (detectando correctamente siniestros),
- Un control del volumen de FP (minimizando falsas alarmas),
- Una degradación contenida del *recall* respecto al punto de corte 0.5 tradicional.

Específicamente, un valor de umbral en torno a 0.45 representa una solución de compromiso óptima para contextos donde se pretende realizar una preselección de casos potenciales con alto riesgo de siniestro, maximizando cobertura sin comprometer en exceso la fiabilidad del sistema. Asimismo, a partir de un *cut-off* mayor (e.g., 0.55 o superior), se obtiene una reducción importante del número de FP, pero a costa de una caída abrupta en el *recall*, lo que implicaría dejar sin detectar una proporción importante de siniestros reales.

Sin embargo, lo que se quiere trasladar en este punto es como la elección del umbral óptimo no es puramente estadística, sino operativa, y debe ser definida en función de los objetivos específicos del negocio asegurador, los recursos disponibles para seguimiento, y la tolerancia al riesgo de falsa alerta.

3.6.3. Calibración de la curva de probabilidades

La predicción del riesgo de siniestralidad no debe entenderse únicamente como una tarea de clasificación binaria, sino como un problema de estimación probabilística individualizada. Desde una perspectiva técnica y de negocio, el objetivo no es solo identificar si un siniestro ocurrirá o no, sino cuán probable es que ocurra, dadas las características observadas del cliente o contrato. Esta transición conceptual (de clases a probabilidades) es lo que permite integrar los modelos dentro de procesos de tarificación, provisión o priorización operativa.

En este contexto, la calibración del modelo adquiere un papel central. Un clasificador discriminante pero mal calibrado puede ordenar correctamente las observaciones, pero asignar probabilidades inconsistentes con las frecuencias empíricas reales, lo que compromete la interpretación del score como estimación de riesgo. Por ello, una vez seleccionado el modelo óptimo en términos de capacidad discriminativa es necesario evaluar y, en su caso, corregir su calibración para asegurar que las probabilidades generadas puedan utilizarse como medidas coherentes y fiables de riesgo asegurador.

3.6.3.1. Del siniestro al "riesgo de siniestro": Calibración del espacio de probabilidad

Supongamos que un modelo predice una probabilidad de siniestro del 60% para un individuo. No obstante, al analizar empíricamente dicho segmento, se constata que la proporción real de siniestros es del 10%. En este caso, el modelo está sobrestimando el riesgo, lo cual puede inducir decisiones erróneas desde una perspectiva operativa o de negocio. Por ejemplo:

Caso 1: Pricing de seguros

Cuando se utiliza directamente la probabilidad predicha como entrada del sistema de tarificación:

- Se podría asignar una prima excesiva a clientes con riesgo moderado, comprometiendo la competitividad.
- Se puede infravalorar el coste real en clientes verdaderamente riesgosos, afectando la rentabilidad técnica.

Caso 2: Selección de cartera o *underwriting*

En procesos donde se establece un umbral de aceptación (*cut-off*), una mala calibración puede provocar:

- Rechazo de buenos clientes debido a sobrestimación del riesgo.
- Aceptación de clientes de alto riesgo si se subestima la probabilidad.
- Se debe entonces decidir sobre umbrales en base a scores calibrados.

Caso 3: Cuando se selecciona el top N de mayor riesgo para una auditoría o intervención, se debe verificar que:

- El orden del score sea adecuado (discriminación: ROC-AUC).
- La proporción predicha coincida con la observada, especialmente si se estiman pérdidas agregadas.

Por ello se debe calibrar la curva de probabilidades resultante del modelo y es importante constar como este proceso no mejora el poder discriminante del modelo, pero alinea las probabilidades con la frecuencia empírica, siendo crucial cuando:

- Se requiere consistencia y trazabilidad del sistema.
- El modelo presenta varios usos determinados, como por ejemplo estimar pérdidas esperadas como: $E[\text{Pérdida}] = P(\text{Siniestro}) \times \text{Severidad}$

Existen múltiples enfoques para la calibración probabilística como el escalado sigmoide, la regresión isotónica o métodos bayesianos. Cada uno con ventajas según la complejidad del score/valor inicial y el tamaño de la muestra. En este trabajo se implementará la regresión isotónica, una técnica no paramétrica que preserva el orden y ajusta de forma flexible la probabilidad estimada a las frecuencias empíricas observadas, siendo adecuada en contextos de desbalance severo como el presente.

El detalle metodológico, así como la aplicación de la calibración sobre el contexto del proyecto se detalla en el Anexo: **Calibración de la curva de probabilidad**.

Es importante destacar que, para poder aplicar la calibración, se requiere que el modelo no esté previamente calibrado internamente (como podría ocurrir si se aplicara un entrenamiento con log_loss y regularización extrema). Por ello, lo empleamos tras entrenar el modelo con una métrica de ordenación como AUC, como se ha hecho en el presente caso de uso. A continuación, mostramos visualmente el efecto de la calibración sobre la muestra de entrenamiento:




Figura 16. Visualización de la curva de probabilidad calibrada y sin calibrar

[1] Antes de calibrar, el modelo sobreestimaba la probabilidad de siniestro. La curva de calibración azul del gráfico anterior se encontraba por debajo de la diagonal, reflejando dicha sobre confianza.

[2] Después de calibrar con regresión isotónica, las probabilidades se distribuyen en $[0, 0.1]$ y la curva naranja se aproxima mucho más a la diagonal ideal. Esto mejora la correspondencia entre probabilidad predicha y frecuencia observada.

Para evaluar la calidad de la calibración probabilística, se emplea el Brier Score, definido como la media del error cuadrático entre la probabilidad estimada y la etiqueta real. Un valor bajo indica buena calibración, ya que las probabilidades se ajustan estrechamente a las frecuencias observadas. Cuanto más bajo, mejor calibrado está el modelo. Tras la calibración de nuestro modelo, obtenemos los siguientes Brier Scores (pre y post calibración), denotando una correcta lógica de implementación de la calibración:

- **Brier Score (original):** 23%
- **Brier Score (calibrado):** 3,5%

3.7. Explicabilidad

En entornos complejos y altamente regulados como se caracteriza el sector asegurador, la interpretabilidad del modelo no es un aspecto accesorio, sino un requisito funcional y normativo. No basta con que un modelo prediga correctamente, sino que es necesario entender por qué lo hace, cómo se estructuran sus decisiones y qué variables influyen de forma significativa en sus resultados. Esta necesidad se intensifica en modelos no lineales o de alta capacidad, como el *ensembling* de árboles o las redes neuronales que, si bien ofrecen un rendimiento superior, tienden a operar como cajas negras desde el punto de vista del usuario final.

En este contexto, surge el marco de la Inteligencia Artificial Explicable (XAI, por sus siglas en inglés), que busca dotar de transparencia, trazabilidad y auditabilidad a los sistemas de aprendizaje automático. La explicabilidad permite:

- Comprender el razonamiento subyacente a cada predicción
- Detectar sesgos o inconsistencias en las variables utilizadas
- Validar la coherencia del modelo con el dominio experto
- Justificar decisiones ante reguladores o partes interesadas

Entre los métodos más consolidados destacan:

- **LIME (Local Interpretable Model-agnostic Explanations)**, que aproxima localmente el comportamiento del modelo en torno a una observación mediante modelos lineales interpretables.
- **SHAP (SHapley Additive exPlanations)**, basado en teoría de juegos cooperativos, que asigna a cada variable una contribución marginal al output del modelo, cumpliendo propiedades deseables como aditividad, simetría y consistencia.

Ambos métodos comparten el objetivo de descomponer la predicción de modelos complejos en componentes comprensibles por humanos, pero lo hacen desde enfoques distintos: SHAP proporciona explicaciones consistentes global y localmente, mientras que LIME ofrece interpretabilidad local de forma rápida y flexible.

Dado el objetivo de este trabajo (predicción y gestión del riesgo de siniestralidad),- la explicabilidad no solo aporta valor metodológico, sino también operativo, al permitir traducir probabilidades en razones comprensibles y defender las decisiones automatizadas dentro del ciclo de vida del riesgo de manera que sean trazables y entendibles por cualquier usuario.

Un carácter/definición más teórica de ambos métodos (SHAP y LIME), se detalla en el Anexo: **Explicabilidad (LIME y SHAP)**, si bien a continuación se procede con la observación de la explicabilidad sobre casos tangibles de nuestro planteamiento:

3.7.1. Análisis de una predicción individual con LIME

LIME genera un modelo lineal interpretable localmente ajustado a una vecindad perturbada del punto a explicar, en este caso, sobre el primer registro del *dataset*. El resultado que obtenemos:




Figura 17. Ejemplo de funcionamiento de Lime sobre una observación del dataset

La probabilidad predicha es 0.48 para clase positiva (Sí) y 0.52 para clase negativa (No). El modelo, por tanto, se sitúa en una región que podríamos designar de elevada incertidumbre, muy próxima al umbral de decisión estándar (0.5), lo que refleja un caso de frontera estadística.

El modelo ha sido influenciado por múltiples variables con contribuciones marginales pequeñas, lo que sugiere que ninguna característica presenta una clara dominancia sobre la decisión local, sino que esta se sustenta en una acumulación de señales débiles. Los *features* más marcados son:

- `ps_ind_17_bin = 0` contribuye hacia la clase No:
Esto significa que, cuando esta variable toma valor 0, la predicción final se empuja hacia la clase 0 (no siniestro). Desde una perspectiva estadística, en el entrenamiento el valor 0 de esta variable probablemente esté asociado con una menor probabilidad de siniestralidad.
- `ps_reg_02_0.1 = 0` contribuye hacia la clase Sí:
La variable transformada `ps_reg_02_0.1 = 0` resulta del *one-hot encoding*. Su valor 0 indica ausencia de esta categoría. Sin embargo, en este contexto específico, su ausencia se asocia a un mayor riesgo, lo que significa que otras categorías diferentes a la 0.1 presentan más siniestralidad.

La observación en particular presenta muchas variables con contribuciones pequeñas en direcciones opuestas. Esto implica que no hay un único factor dominante, sino que el modelo construye la probabilidad de forma acumulativa a partir de señales débiles. Esto es típico en modelos tabulares de riesgo donde la señal es difusa y multicausal.

Los valores individuales de cada variable pueden favorecer o penalizar la predicción de siniestralidad, dependiendo de su asociación aprendida durante el entrenamiento. En LIME, un valor puede contribuir a la clase positiva o negativa dependiendo de su dirección estimada localmente. Es importante entender que esta contribución no es global, sino específica de la instancia analizada.

Este tipo de explicaciones son útiles para auditoría individual de decisiones, sobre todo en casos de frontera (como este: 52% vs 48%). El comportamiento del modelo en este punto refleja una región de baja separabilidad del espacio de representación. Esto puede deberse a una señal estructural débil o a una configuración de variables que no permite una separación lineal o no lineal clara.

El uso de LIME ha permitido validar que, para esta instancia, la predicción es débilmente soportada por el modelo, lo que podría tener implicaciones en la confianza operativa de la decisión si esta instancia es crítica (ej. cliente de alto valor económico).

3.7.2. Análisis SHAP local

La obtención de los SHAP *values* a nivel local para una predicción nos devuelven la siguiente imagen:




Figura 18. Explicabilidad local con SHAP sobre ejemplo del dataset

La predicción realizada por el modelo XGBoost para una observación concreta se explica mediante la descomposición aditiva proporcionada por SHAP. En este caso:

- el valor predicho es: $f(x) = 0.497$,
- partiendo de un valor esperado global (*base rate* del modelo): $E(f(x)) = 0.485$.
- Esto implica que la combinación específica de variables para este individuo ha generado un ligero incremento en el riesgo estimado de siniestralidad, con una contribución neta total de:

$$\sum_{j=1}^p \phi_j = 0.012$$

Elementos clave del gráfico:

- **Valor base:** representa la expectativa del modelo antes de ver los datos (media de predicciones).
- **Barras rojas:** variables que aumentan la predicción (acercan al resultado positivo).
- **Barras azules:** variables que reducen la predicción (acercan al resultado negativo).

Contribuciones individuales más relevantes:

- $ps_car_13 = 1.154$ contribuye +0.04 al riesgo predicho. Es el efecto dominante. Este valor (por encima de la media poblacional) se interpreta como un marcador de riesgo elevado, posiblemente por su relación con características del vehículo o asegurado que aumentan la siniestralidad.
- $ps_ind_16_bin = 1$ contribuye -0.01, lo que sugiere que esta condición binaria se asocia con mayor estabilidad o menor riesgo.
- $ps_ind_06_bin = 0$ tiene un efecto positivo de +0.01, por lo que su ausencia indica cierta debilidad o mayor exposición al riesgo.

- $ps_reg_03 = -0.354$ con contribución -0.01 , este valor reducido de una variable regional puede indicar un contexto geográfico de baja siniestralidad.

Otras variables aportan efectos marginales, configurando un patrón de agregación de micro efectos que es típico en problemas de señal débil con múltiples variables categóricas.

La predicción final de 0.497 refleja una combinación equilibrada de señales débiles, sin dominancia extrema de ninguna variable salvo ps_car_13 . La predicción se sitúa muy cerca del umbral de decisión 0.5, lo que confirma la incertidumbre del modelo sobre este individuo concreto.

3.7.3. Análisis SHAP global

Para la explicabilidad global con SHAP, se ha llevado a cabo un análisis sobre una muestra aleatoria de 100 observaciones del conjunto de *test*. Este enfoque permite evaluar cómo cada variable contribuye, en promedio, a las decisiones del modelo en toda la muestra, siguiendo una descomposición aditiva. El resultado es el siguiente:




Figura 19. Explicabilidad Global con SHAP sobre conjunto aleatorio del *dataset* (1)




Figura 20. Explicabilidad Global con SHAP sobre conjunto aleatorio del *dataset* (2)

Observamos dos representaciones graficas:

- **Bar Plot (SHAP Summary):** Muestra el impacto medio absoluto de cada variable sobre la predicción. Variables como ps_car_13, ps_reg_03 o ps_ind_17_bin son las más influyentes, lo que revela su poder discriminativo global.
- **Beeswarm Plot:** Complementa lo anterior mostrando la dispersión de los valores SHAP por variable, junto con una codificación de color que representa el valor real de la variable. Este tipo de gráfico permite visualizar interacciones complejas y posibles efectos no lineales.

Los valores SHAP son coherentes con la teoría de juegos (valor de Shapley), garantizando equidad en la atribución de contribuciones incluso en presencia de correlación entre variables. La suma de todos los SHAP de una observación más el valor base devuelve exactamente la probabilidad estimada por el modelo, validando la descomposición. Del caso específico, variables como ps_car_13 y ps_reg_03 presentan impactos estructurales relevantes y estables en el output del modelo. La variabilidad observada en algunas variables sugiere posibles interacciones latentes o efectos de subgrupos, lo cual motiva análisis futuros.

Consideraciones específicas:

La incorporación de técnicas de explicabilidad como LIME y SHAP permite cerrar el ciclo de modelización con una visión completa que va más allá del rendimiento predictivo. Estos métodos proporcionan transparencia y trazabilidad a modelos inicialmente opacos como XGBoost, haciendo posible tanto la validación interna del comportamiento del modelo como la comunicación clara de resultados a perfiles no técnicos o responsables de negocio.

Mientras que LIME facilita interpretaciones locales rápidas en torno a observaciones individuales, resultando útil para auditoría de decisiones o análisis de casos frontera, SHAP ofrece un marco más robusto, consistente y matemáticamente fundamentado que permite explicaciones tanto locales como globales, manteniendo propiedades deseables de equidad y aditividad.

Los ejemplos presentados demuestran que ambas herramientas son complementarias en el proceso de interpretación, ayudando a:

- Identificar las variables que activan la predicción de siniestralidad,
- Detectar posibles anomalías o decisiones inesperadas del modelo,
- Contrastar la coherencia de las decisiones automáticas con el conocimiento experto.

En contextos regulados como el asegurador, donde la confianza, la justificación y la supervisión de los sistemas algorítmicos son requisitos, el uso de métodos XAI representa una garantía adicional de fiabilidad, auditoría y alineación con el dominio de negocio.

Este marco de explicabilidad es el que permite que un modelo predictivo no solo sea estadísticamente eficaz, sino también operacionalmente útil, éticamente defendible y técnicamente trazable.

3.8. Producción (basis): despliegue y operacionalización del modelo de siniestralidad

Una vez desarrollado, validado y calibrado el modelo predictivo de siniestralidad, el siguiente paso natural consiste en definir su integración en un sistema capaz de ofrecer inferencias en tiempo real o bajo demanda, de forma robusta, trazable, reproducible y auditada. En entornos reales (y especialmente en dominios regulados como el asegurador), el valor del modelo no se limita a su rendimiento estadístico, sino a su capacidad de ser expuesto como un servicio confiable, mantenible y auditable en el ciclo de vida completo de decisiones.

Con este propósito, se ha diseñado un sistema modular que simula los componentes necesarios para una puesta en producción real. Aunque el presente trabajo incluye una propuesta completa de operacionalización del modelo de siniestralidad, es importante aclarar que dicha implementación se ha desarrollado con un enfoque teórico y demostrativo, no productivo. Esto responde a los límites previamente definidos del proyecto, centrado en la construcción metodológica y validación cuantitativa del modelo, más que en su integración en sistemas reales.

El diseño arquitectónico aquí presentado —incluyendo el pipeline de inferencia, la API REST, el *dashboard* interactivo y el entorno de despliegue mediante Docker— ha sido construido con el objetivo de ilustrar una visión técnica coherente, escalable y alineada con buenas prácticas de MLOps, tal como sería exigible en entornos aseguradores reales. Sin embargo, no se ha procedido a su implementación sobre infraestructura productiva ni a su orquestación mediante herramientas de CI/CD, contenedores en la nube o sistemas de gestión de modelos.

Esta decisión permite demostrar el conocimiento y aplicabilidad de estos principios, al tiempo que se mantiene el foco del trabajo dentro del alcance definido: la construcción, validación, calibración e interpretabilidad de un modelo robusto de ordenación para riesgo de siniestralidad. La estructura presentada actúa, así como un marco conceptual

funcionalmente reproducible, susceptible de ser desplegado con mínimos ajustes técnicos en cualquier entorno profesional.

Consideraciones específicas:

A lo largo del desarrollo del flujo analítico y experimental —implementado de forma modular y documentada en el cuaderno de trabajo (notebook)— se han ido generando y almacenando los distintos artefactos que resultan imprescindibles para la puesta en producción del modelo :

- El modelo final entrenado y calibrado (modelo_XGBoost.pkl),
- El imputed de valores faltantes para variables categóricas (imputer_cat.pkl),
- El codificador de variables categóricas (encoder.pkl),
- Las listas estructuradas de variables (categorical_vars, binary_vars, continuous_vars).

Estos objetos han sido persistidos siguiendo buenas prácticas de trazabilidad, lo que permite su reutilización directa en el pipeline de inferencia diseñado. Gracias a esta estructura modular, la transición desde la fase experimental hacia un sistema reproducible y potencialmente desplegable se realiza de forma fluida y controlada, minimizando la posibilidad de desalineación entre los entornos. Esta estrategia anticipada de persistencia facilita la automatización de procesos y constituye una base sólida para futuras fases de integración en entornos operativos reales.

3.8.1. Descripción técnica y funcional de los componentes

El sistema de modelado se organiza en torno a una estructura modular orientada a la separación de responsabilidades. Cada módulo cumple una función específica dentro del ciclo de inferencia y exposición del modelo. A continuación, se detalla la función técnica y justificación de cada uno de ellos:

```

nl_scoring_api/
├── config.py
│   # Contiene configuraciones generales del entorno (dev, prod, test), paths de modelos, logging, flags,
│   # etc ...
├── scoring_pipeline.py
│   # Función principal de predicción, reutiliza todo el preprocesamiento realizado en el entrenamiento:
│   import [...]
│
│   # Carga de objetos persistidos
│   modelo_final = joblib.load("model/modelo_XGBoost.pkl")
│   encoder = joblib.load("model/encoder.pkl")
│   imputer_cat = joblib.load("model/imputer_cat.pkl")
│   from variables import categorical_vars, binary_vars, continuous_vars
│
│   def predecir(input_df):
│       [...] DETALLE TEÓRICO ABAJO]
├── api/
│   ├── main.py
│   │   # API REST con FastAPI. Expone un endpoint /predict que recibe JSON y devuelve predicción
│   │   from fastapi import FastAPI
│   │   from pydantic import BaseModel
│   │   import pandas as pd
│   │   from scoring_pipeline import predecir
│   │
│   │   app = FastAPI()
│   │
│   │   class InputData(BaseModel):
│   │       features: dict
│   │
│   │   @app.post("/predict")
│   │   def predict(data: InputData):
│   │       df = pd.DataFrame([data.features])
│   │       proba = predecir(df)
│   │       return {"probabilidad": float(proba[0])}
│   │
│   ├── schemas.py
│   │   # Validación de entrada con Pydantic
│   │   from pydantic import BaseModel
│   │   from typing import Dict
│   │
│   │   class InputSchema(BaseModel):
│   │       features: Dict[str, float]
├── streamlit_dashboard/
│   ├── app.py
│   │   # Interfaz visual con Streamlit que permita la subida de un CSV o introducir valores manuales para
│   │   # pred.
│   │   import streamlit as st
│   │   import pandas as pd
│   │   from scoring_pipeline import predecir
│   │
│   │   st.title("Scoring de Riesgo de Siniestralidad")
│   │   uploaded_file = st.file_uploader("Sube un archivo CSV")
│   │
│   │   if uploaded_file:
│   │       df = pd.read_csv(uploaded_file)
│   │       proba = predecir(df)
│   │       st.write("Probabilidad de siniestro:", proba)
├── model/
│   ├── modelo_XGBoost.pkl
│   ├── encoder.pkl
│   └── imputer_cat.pkl
├── variables.py
│   # Variables usadas en todo el pipeline: categóricas, binarias, continuas
│   categorical_vars = [...]
│   binary_vars = [...]
│   continuous_vars = [...]
└── Dockerfile
    # Imagen contenedora del API para correr en producción
    # FROM python:3.11
    # COPY ./app
    # WORKDIR /app
    # RUN pip install -r requirements.txt
    # CMD ["uvicorn", "api.main:app", "--host", "0.0.0.0", "--port", "8080"]

```

Figura 21. Flujo de implementación teórica del despliegue del modelo.

config.py: parametrización centralizada

Este módulo actúa como núcleo de configuración del sistema de producción, permitiendo definir:

- Entornos de ejecución (*dev./test/ prod.*)
- Rutas relativas para artefactos persistidos
- Parámetros por defecto (como umbrales o *seeds*)

Su objetivo sería centralizar la configuración, evitando efectos colaterales por cambios dispersos y facilitando la trazabilidad, reproducibilidad y mantenimiento del sistema.

scoring_pipeline.py: motor de inferencia

Este archivo implementa el pipeline completo para la aplicación del modelo. En concreto:

- Carga el modelo entrenado (XGBoost calibrado) desde el “.pkl” que hemos definido
- Aplica imputación de valores faltantes,
- Aplica transformaciones (*encoding*) idénticas a las del entrenamiento
- Realiza la predicción y retorna probabilidades calibradas.

El *core* principal de `scoring_pipeline` es la función `predecir`, que encapsula la lógica de inferencia y asegura que todo nuevo dato pase por el mismo flujo que se aplicó en entrenamiento, garantizando la ausencia de fuga de datos (*data leakage*) y evitando inconsistencias. A continuación, se muestra una definición programática de cómo sería esta función:

```
# scoring_pipeline.py
def predecir(input_df, modelo_final, encoder, imputer_cat, binary_vars, continuous_vars, categorical_vars):
    """
    Aplica el preprocesamiento y devuelve la probabilidad de siniestralidad.

    Parameters:
    - input_df: DataFrame de entrada (1 o varios registros).
    - modelo_final: Modelo entrenado (XGBoost).
    - encoder: OneHotEncoder fitted.
    - imputer_cat: Imputador categórico fitted.
    - binary_vars, continuous_vars, categorical_vars: listas de variables según tipo.

    Returns:
    - np.array: Probabilidades predichas.
    """

    # Validación de columnas mínimas necesarias
    columnas_requeridas = binary_vars + continuous_vars + categorical_vars
    missing_cols = [col for col in columnas_requeridas if col not in input_df.columns]
    if missing_cols:
        raise ValueError(f'Faltan columnas en el input: {missing_cols}')

    # Imputación y transformación
    X_cat = imputer_cat.transform(input_df[categorical_vars])
    X_cat_encoded = encoder.transform(X_cat)
    X_bin = input_df[binary_vars].values
    X_quant = input_df[continuous_vars].values

    # Concatenar todas las variables preprocesadas
    X_processed = np.hstack([X_cat_encoded, X_bin, X_quant])

    # Predicción
    probas = modelo_final.predict_proba(X_processed)[1, :]
    return probas
```

Figura 22. Función de predicción del *bucket* de producción `scoring_pipeline.py`

variables.py: consistencia estructural

A modo genérico, este *bucket* contendría las listas de:

- Variables categóricas (`categorical_vars`),
- Variables binarias (`binary_vars`),
- Variables continuas (`continuous_vars`).

Estas definiciones se utilizan tanto en el entrenamiento como en la inferencia, asegurando consistencia estructural a lo largo de todo el sistema. Permite desacoplar la lógica de preprocesado del listado estático, mejorando mantenibilidad y trazabilidad.

api/main.py: exposición del modelo vía API REST

Este módulo implementa una API REST usando FastAPI, altamente eficiente y compatible con servidores ASGI (como Uvicorn).

- Define un *endpoint* `/predict`,
- Recibe datos en formato JSON,
- Realiza validación de entrada (vía Pydantic),
- Ejecuta `predecir()` sobre los datos y devuelve una probabilidad como respuesta.

El principal objetivo se sustenta en separar el motor de inferencia del mecanismo de entrada permite reutilizar el pipeline desde múltiples interfaces (API, *dashboards*, *scripts*). Además,

expone el modelo como microservicio autocontenido, una buena práctica en arquitecturas modernas orientadas a servicios.

api/schemas.py: validación estructural

Uso de herramientas tipo Picantico para validar que los datos entrantes:

- Cumplen con la estructura esperada,
- Tienen el tipo correcto por variable.

Esta validación temprana evita errores de entrada, garantiza robustez del *endpoint* y mejora la protección contra errores operativos o ataques de tipo *injection*.

streamlit_dashboard/app.py: interfaz visual explicativa

Dashboard interactivo construido con Streamlit, orientado a:

- Equipos de negocio que deseen realizar pruebas manuales
- Técnicos que necesiten verificar outputs puntuales
- Pruebas de integración de flujo completo.

La idea basis sería la capacidad de cargar un artefacto (e.g CSV) o introducir manualmente valores, que, con una llamada a la predicción, muestre en pantalla la probabilidad de siniestro. Es un ejemplo de *front-end* ligero conectado al motor de inferencia vía importación directa, pero puede extenderse fácilmente a consumir la API REST.

model: artefactos persistidos

Bucket que contendría:

- El modelo calibrado obtenido tras el flujo de entrenamiento (modelo_XGBoost.pkl),
- El *encoder* de variables categóricas (encoder.pkl) obtenido durante el flujo de entrenamiento
- El imputador de variables (imputer_cat.pkl), también obtenido durante el flujo de entrenamiento.

Estos objetos se persisten tras el entrenamiento y se cargan dinámicamente en *scoring_pipeline.py*, permitiendo despliegue y escalado sin necesidad de reentrenamiento.

Dockerfile: contenedor de despliegue

Define una imagen reproducible del sistema usando Docker:

- Entorno Python controlado (versión fija)
- Instalación exacta de librerías (requirements.txt)
- Exposición del servidor vía uvicorn.

Esto permite empaquetar el modelo como una unidad autocontenida, portable y desplegable en entornos *cloud*, entornos de CI/CD o pipelines de integración continua.

4. Resultados

A lo largo de la sección 2 (Materiales y métodos), se ha seguido una línea lógica de desarrollo de todas las fases del proyecto, siguiendo un enfoque natural de respuesta a un planteamiento analítico, en este caso relacionado con el riesgo de siniestralidad. En ese contexto, se han ido presentando consideraciones y puntos de interés que han derivado en resultados con la finalidad de entender y justificar los apartados/puntos que seguían. Por esa razón, el objetivo de este apartado es sintetizar los principales hitos y resultados obtenidos tras la aplicación completa del marco metodológico propuesto.

La explotación sobre un conjunto de datos de naturaleza desbalanceada y ofuscado, a efectos de las variables que lo componen, con la finalidad de orientar el planteamiento hacia un enfoque predictivo en materia de riesgo siniestralidad donde observar se desarrollan múltiples modelos de clasificación supervisada se corresponde con el eje principal de desarrollo del proyecto. A este, se le suma un procedimiento exhaustivo de entendibilidad del conjunto de datos -guiado por una selección de un subconjunto para la modelización basado en capacidad predictiva empírica de cada *feature* sobre el evento de siniestro-, una calibración de la curva de probabilidad resultante de la modelización del target binario, una ajustada evaluación del proceso de modelización y de la mejor solución encontrada que pasa por dotar de una correcta explicabilidad dentro del marco de *Explainable AI*, así como un enfoque teórico de la puesta en producción de la solución.

Este apartado recoge de forma sistemática y estructurada los principales hallazgos obtenidos tras la aplicación completa del marco metodológico propuesto, resumido en el párrafo anterior. Si bien a lo largo del desarrollo se han ido introduciendo interpretaciones y consideraciones intermedias, el presente capítulo sintetiza los resultados más relevantes desde una perspectiva técnico-analítica, incorporando la performance cuantitativa de los modelos, sus limitaciones estructurales, la calidad de las probabilidades estimadas y la viabilidad operativa de su despliegue en entornos aseguradores reales.

Diagnóstico inicial y estructura del *dataset*

El conjunto de datos analizado presenta una complejidad significativa desde el punto de vista estadístico y operativo. Por esa razón, se clasifica como un problema bajo un *dataset* ofuscado pues no se tiene consciencia situacional del sentido de negocio de cada variable – estando estas en muchos casos manipuladas según la lectura que hacemos del *dataset raw* -, más allá del conocimiento de la estructura de su codificación que limita la interpretación semántica y dificulta la incorporación de conocimiento experto.

Además, el evento de interés (la ocurrencia de siniestros), se caracteriza por estar altamente desbalanceada, con una tasa base aproximada del 4% sobre el total del *dataset*, de manera natural a lo que un planteamiento de riesgo supone. Este hecho condiciona el enfoque de modelado, al tratarse de un caso prototípico de *rare event prediction*, exigiendo un tratamiento cuidadoso del desbalanceo, tanto en términos de ajuste del clasificador como de evaluación del rendimiento.

La identificación marcada de la heterogeneidad tipológica en las variables (binarias, categóricas, numéricas escaladas) ha dado lugar a la construcción de un pipeline de preprocesamiento modular y reproducible, capaz de tratar de forma robusta la imputación, codificación y transformación de los datos, garantizando coherencia entre las fases de entrenamiento e inferencia posterior.

Selección estadística de variables predictoras

Dada la imposibilidad de interpretar directamente el contenido semántico de las variables, se ha diseñado un proceso riguroso y reproducible de selección de predictores basado exclusivamente en criterios estadísticos. A partir del total de set de predictores disponibles, el proceso se ha diseñado tomando en consideración medidas univariantes de capacidad predictiva, validación de multicolinealidad mediante y evaluación de separabilidad por clases con el estadístico KS para cada predictor.

La creación de una métrica agregada de métricas univariantes y su posterior dicotomización mediante Otsu (el cual se ha reconducido desde su aplicación originaria), para identificar un umbral óptimo en la distribución del score agregado, ha resultado en un pipeline de procesamiento y selección empírico y robusto, escalable a cualquier marco de datos.

Modelado

Se han entrenado y validado cuatro modelos supervisados: Regresión Logística, XGBoost, LightGBM y TabNet, todos ellos ajustados mediante búsqueda bayesiana de hiperparámetros con Optuna, empleando la métrica ROC-AUC como objetivo. De este proceso, se sustenta como Optuna, combinando la exploración bayesiana y evaluando de manera iterativa sobre el conjunto de validación, alcanza una configuración robusta y reproducible para cada arquitectura. Adicionalmente, se incorporaron mecanismos de compensación por desbalanceo, tales como `class_weight='balanced'`, `scale_pos_weight`, y criterios de parada temprana, de manera que los enfoques predictivos tuviesen sensibilidad del desbalanceo del target.

De todos los modelos, XGBoost ha sido el que ofrece el mejor compromiso entre capacidad discriminante, estabilidad y rendimiento operativo. Dicha solución cuantitativa se caracteriza por obtener un ROC-AUC superior a 0.61, mostrando una capacidad limitada para discriminar siniestros reales frente a no siniestros en todo el rango de posibles umbrales de decisión, así como un PR-AUC, que supera la tasa base del 4%, lo cual valida que el modelo captura señal útil para identificar correctamente eventos poco frecuentes.

La lectura directa de dichos resultados ha conllevado a reconsiderar y entender de cerca el planteamiento analítico, pues a pesar del ajuste fino de cada arquitectura y del uso de métricas robustas adaptadas a datos desbalanceados, los resultados obtenidos muestran limitaciones claras en la predicción de la clase minoritaria (siniestros). Esta limitación, tras tratar detalladamente los enfoques predictivos y ajustarlos de manera ajustada al planteamiento en cuestión (proceso de selección de hiperparámetros ajustado y robusto

frente al desbalanceo), no se atribuye de manera directa a la solución predictiva en sí, sino a la falta de separabilidad estadística inherente a las variables disponibles del conjunto de datos. Estas limitaciones se reflejan en:

- La baja ganancia marginal entre modelos complejos y la regresión logística, lo que sugiere que la estructura del *dataset* no permite aprovechar relaciones no lineales profundas.
- La degradación del *recall* en modelos como TabNet, que tienden a sobre ajustarse a la clase mayoritaria sin aportar diferenciación relevante.
- El bajo poder explicativo de las variables respecto al evento de siniestralidad, posiblemente derivado de su carácter agregado, ofuscado o incompleto, representa el principal cuello de botella de la modelización. Un subconjunto que, empíricamente se ajusta como el más predictivo pero que, evaluado en términos absolutos, presenta muy baja capacidad discriminante del *target* (*Information Value*, Gini y *Permutation Importance*) del preprocesado previo a la modelización.

Dichas limitaciones se constatan bajo una problemática estructural y no técnica, concluyendo como el rendimiento observado está más condicionado por la calidad informacional del *dataset* (ofuscación, ruido, falta de granularidad), que por la capacidad técnica de los modelos. Aún y así, el análisis y diagnóstico de la matriz de confusión del mejor modelo obtenido, permite simular y entender distintos escenarios de negocio: priorización de *recall* frente a precisión, o balance entre cobertura y coste operativo, siendo estos elementos clave en un negocio asegurador.

Este análisis posterior aporta criterios cuantitativos para la toma de decisiones en escenarios reales donde el riesgo de siniestro debe activarse bajo condiciones de ambigüedad.

Calibración

La calibración de las probabilidades predichas es fundamental cuando el output del modelo se interpreta como una estimación del riesgo siniestral, no solo como una clasificación. Se ha empleado regresión isotónica como técnica no paramétrica para ajustar la salida del modelo a la frecuencia real observada y esta ha permitido ajustar la curva de probabilidad del planteamiento hacia un escenario más realista, evidenciando las necesidades de este proceso, muy común en entornos altamente regulados como es el ámbito asegurador.

Explicabilidad del modelo y trazabilidad de decisiones

El uso de técnicas de *explainable AI*, como SHAP y LIME, dota al modelo de una capa adicional de interpretabilidad, la cual es completamente necesaria cuando la solución analítica pasa por modelos cuya interpretación resulta no ser trivial. En ese contexto, se concluye como tanto SHAP, con su contenido Global y local, como LIME, únicamente local, son dos técnicas que permiten tener consciencia situacional de cómo el modelo está prediciendo.

El uso de estas permite un cambio de paradigma entre los equipos técnicos y de negocio de una institución, pues principalmente cumple con el objetivo de hacer explicable la solución y

por tanto de acercarla hacia personas más lejanas al entorno técnico (e.g. analistas que están en primera línea de defensa evaluando la aceptación de pólizas).

Estas técnicas no solo mejoran la comprensión del modelo, sino que también habilita su validación ante entornos reguladores y facilita su integración en procesos internos de auditoría o revisión manual.

Implementación técnica y despliegue teórico

Finalmente, aunque su despliegue no se ha materializado de manera tangible, se plantea un entorno para la puesta en producción sobre un entorno productivo real, contextualizado sobre una arquitectura modular completa que se basa en:

- Un pipeline reproducible en Python,
- Una API REST con FastAPI,
- Una interfaz de usuario con Streamlit,
- Contenedores con Docker.

Esta estructura permitiría poner en disposición al modelo en cualquier entorno de forma trazable, escalable y auditable, garantizando la coherencia entre las transformaciones aplicadas en entrenamiento e inferencia, preservando la integridad del sistema y facilitando su industrialización futura. A pesar de que las métricas de error para seleccionar el mejor modelo alcanzan niveles limitados, el modelo final —XGBoost calibrado— representa una solución robusta y defendible en términos de explicabilidad y viabilidad funcional para la estimación del riesgo de siniestralidad. La arquitectura desarrollada es coherente, reproducible y compatible con los requisitos del sector asegurador. En resumen:

El modelo XGBoost destaca por su capacidad para proporcionar interpretaciones claras y comprensibles de sus predicciones facilitando la comprensión y la justificación de las decisiones tomadas por el modelo, siendo un elemento crucial en el sector asegurador. En lo relativo al performance, se concluye como las limitaciones del conjunto de datos (en términos de interpretación semántica -ofuscación-, la presencia de un evento desbalanceado, la baja capacidad predictiva de los predictores en términos absolutos...), se trasladan al contexto de modelización donde, a pesar de haber ajustado las soluciones mediante hiperparametría básica sobre conjuntos desbalanceados se obtiene un poder limitado (ROC AUC del 61%).

No obstante, la visión tras estos resultados es distinta, ya que, a pesar de las consideraciones anteriores, tras construir XGBoost y calibrarlo se puede construir una solución predictiva estable y explicable que puede actuar como un primer filtro en la predicción y evaluación de la siniestralidad.

A través de la ingeniería de características realizada previamente a la modelización (pipeline de preprocesado y selección), se pueden extraer patrones significativos que, aunque no sean directamente interpretables, contribuyen de manera sustancial a la precisión del modelo. Además, el uso de técnicas de aprendizaje automático avanzadas permite capturar

relaciones complejas y no lineales entre las variables, mejorando la capacidad predictiva del modelo.

Toda la arquitectura desarrollada, es escalable y se pretende que sea extensiva a conjuntos de datos con mayor poder predictivo en términos globales, donde aplicando el mismo pipeline seguido en el proyecto, se obtenga un sistema con un ajuste mucho más elevado en términos de separación de del evento de siniestro.

En resumen, el trabajo muestra cómo, en presencia de datos ofuscados, eventos desequilibrados y ausencia de interpretación semántica directa, es posible construir un sistema predictivo estable, calibrado, explicable y preparada para ser puesta en producción que puede servir como primera línea de defensa para la toma de decisiones operativas y regulatorias en el sector asegurador en materia de potenciales siniestros.

5. Conclusiones y trabajos futuros

El presente trabajo ha abordado de forma integral la construcción de un sistema predictivo de riesgo de siniestralidad en contextos aseguradores, mediante el uso de técnicas avanzadas de aprendizaje automático bajo un enfoque metodológico riguroso, reproducible y alineado con los estándares del sector regulado. A través de un marco completo que abarca desde la selección empírica de variables hasta la explicabilidad del modelo, se ha implementado una solución funcionalmente viable y estadísticamente defendible.

El modelo final propuesto -basado en XGBoost calibrado mediante regresión isotónica- muestra un comportamiento estructuralmente robusto, con capacidad discriminativa limitada, aunque razonable (teniendo en cuenta las limitaciones de datos), buen comportamiento probabilístico y plena trazabilidad, incluso ante condiciones informacionales desfavorables. La calidad de los resultados obtenidos valida el marco metodológico empleado, aunque también ha revelado las limitaciones intrínsecas del *dataset*.

Reflexión crítica sobre el rendimiento observado:

Los resultados obtenidos muestran una señal predictiva presente pero débil, atribuible a la baja separabilidad estadística de las clases y a la escasa granularidad de las variables disponibles. En consecuencia, aunque los modelos han sido calibrados y optimizados exhaustivamente, su capacidad de capturar siniestros con alta precisión se ha visto condicionada por limitaciones estructurales más allá del modelado.

Este desenlace, lejos de ser decepcionante, resulta esclarecedor: demuestra que incluso con herramientas sofisticadas y ajuste exhaustivo del planteamiento analítico, el valor predictivo de un sistema está determinado en gran medida por la riqueza y relevancia de sus variables. La principal conclusión es que el riesgo de siniestralidad es un problema abordable mediante modelos calibrados e interpretables, pero requiere información predictivamente significativa para rendir a niveles óptimos.

Evaluación de objetivos alcanzados:

Los objetivos formulados al inicio del trabajo han sido alcanzados en su mayoría:

- Diseño de un pipeline modular, reproducible y estructurado para la predicción de siniestros.
- Implementación comparativa de modelos clásicos y avanzados, con ajuste y evaluación rigurosa.
- Selección cuantitativa de variables mediante medidas univariantes.
- Optimización con búsqueda bayesiana (Optuna) e integración de calibración *post-hoc* (regresión isotónica).
- Aplicación de técnicas de explicabilidad local y global (LIME, SHAP).
- Diseño teórico de despliegue en arquitectura productiva (FastAPI, Docker, Streamlit).

El único objetivo parcialmente limitado ha sido la consecución de un rendimiento predictivo alto sobre la clase minoritaria, cuya explicación no se encuentra en la metodología, sino en la limitada capacidad informacional del *dataset*.

Reflexión metodológica y adaptaciones necesarias

La metodología ha sido seguida con precisión, cumpliendo los principios de modularidad, reproducibilidad y escalabilidad. No obstante, se han introducido algunas adaptaciones que han enriquecido sustancialmente el trabajo:

- Incorporación de calibración de probabilidades, al observar que el output del modelo debía ser interpretable en términos de riesgo individual.
- Desarrollo de arquitectura de despliegue teórica, permitiendo demostrar la portabilidad del sistema.
- Visualización estratégica de la matriz de confusión para distintos umbrales, adaptando la interpretación a necesidades de negocio reales.

Estas extensiones metodológicas no alteran el rigor del enfoque original, sino que refuerzan su aplicabilidad operativa y su alineación con las prácticas del sector.

Consideraciones sobre decisiones analíticas clave

Se ha decidido no aplicar técnicas de reducción de dimensionalidad dado que:

- En contextos aseguradores y regulados, la interpretabilidad de los predictores originales es crítica para la trazabilidad y supervisión del modelo.
- La base de datos no presenta un exceso de variables numéricas ni redundancia multivariada severa que justifique este tipo de transformaciones.
- El pipeline se ha diseñado en torno a la capacidad discriminativa empírica de cada predictor frente al evento de interés, en lugar de proyecciones latentes no interpretables.

Del mismo modo, se ha evitado el uso de técnicas de sobre muestreo como SMOTE, que, si bien son frecuentes en la literatura académica, no están generalmente recomendadas en entornos supervisados y regulados, ya que alteran artificialmente la distribución original del target. Se ha preferido preservar la estructura de datos natural y aplicar compensaciones mediante `scale_pos_weight`, `class_weight` y optimización específica de la métrica (AUC), respetando la coherencia estadística del sistema, al ser una práctica habitual en contextos altamente regulados.

Evaluación de impactos ético-sociales y de diversidad

Durante todo el desarrollo, se han observado los principios fundamentales de ética y sostenibilidad:

- Se ha trabajado exclusivamente con datos anonimizados y sin información personal o sensible.
- Se han integrado técnicas de explicabilidad para evitar decisiones opacas o difícilmente auditables tras las soluciones analíticas.

- El sistema es trazable y verificable, y no emplea predictores que puedan inducir sesgos de género, etnia o condición socioeconómica.

Desde el punto de vista social, el modelo puede contribuir a una asignación más equitativa y eficiente del riesgo asegurador, siempre que su uso esté acompañado de mecanismos de supervisión humana. Por ende, no se han detectado impactos negativos de sostenibilidad o diversidad.

Impactos no previstos detectados

Durante el desarrollo del presente trabajo, ha emergido de forma clara un impacto no anticipado inicialmente, pero de gran calado metodológico y estratégico: la necesidad crítica de enriquecer la base informacional del problema para garantizar una capacidad predictiva significativa. Este hallazgo ha surgido no como una conclusión anecdótica, sino como resultado de múltiples observaciones empíricas coherentes a lo largo de todo el pipeline.

A pesar del uso de modelos supervisados de última generación (e.g., XGBoost, TabNet) y de una optimización fina de hiperparámetros y métricas específicas para contextos desbalanceados, la señal discriminativa obtenida sobre la clase minoritaria (siniestros) ha resultado ser débil. Esta limitación no puede atribuirse a una elección inadecuada de algoritmo, métrica o técnica de calibración, ya que todas ellas han sido seleccionadas según criterios de adecuación científica y validados experimentalmente. La causa raíz ha sido identificada en la estructura informacional del *dataset*. En concreto, se ha constatado que:

- Las variables presentan un alto grado de ofuscación semántica, lo que impide el uso de conocimiento experto para enriquecer o interpretar sus relaciones con el target.
- Muchas variables son agregaciones estáticas, que no reflejan comportamientos temporales, relaciones secuenciales o evolución dinámica, elementos clave en la detección de riesgo asegurador.
- No existen variables relacionales, contextuales o ambientales que permitan capturar dependencias estructurales más allá del individuo aislado (e.g., red de contactos, zona geográfica, situación macroeconómica).

En este contexto, el presente trabajo actúa como una llamada de atención metodológica: ningún modelo, por avanzado que sea, puede compensar completamente la ausencia de información relevante o predictiva. De este modo, se constata que el modelado supervisado no es solo una cuestión algorítmica, sino fundamentalmente una cuestión informacional y arquitectónica.

Este impacto no previsto refuerza la visión sistémica del aprendizaje automático en entornos reales: los modelos no sustituyen al entendimiento del dominio, sino que lo amplifican —en la medida en que la arquitectura de datos sea adecuada para ello. Así, se plantea como eje vertebrador de futuros desarrollos la necesidad de repensar el espacio de representación desde una óptica de calidad, granularidad y diversidad informacional.

Líneas de trabajo futuras

El presente trabajo deja abiertas diversas líneas de mejora y extensión que podrán explorarse en futuros desarrollos:

- Enriquecimiento del espacio de predictores: mediante series temporales, datos relacionales, fuentes externas (e.g. climáticas, macroeconomía).
- Modelización causal o estructural: que permita inferir relaciones explicativas más allá de la correlación.
- Técnicas de aprendizaje contrastivo o representación densa: para extraer información latente no lineal de los datos.
- Implementación productiva en entorno *cloud* con MLOps: integrando monitorización, versionado y pruebas automatizadas.
- Validación externa con datos reales: para evaluar desempeño operacional y realizar ajustes finos con *feedback* de negocio.

6. Glosario

Accuracy

Proporción de predicciones correctas respecto al total de observaciones. No es fiable en datasets desbalanceados, ya que puede ocultar un rendimiento pobre sobre la clase minoritaria.

AUC (Area Under the Curve)

Métrica que cuantifica el área bajo una curva ROC o PR. Evalúa la capacidad discriminativa del modelo considerando todos los umbrales posibles.

Bagging

Método de ensamblado que entrena modelos en subconjuntos de datos generados mediante bootstrap y combina sus predicciones para reducir la varianza.

Baseline

Valor base de referencia con el que se comparan las predicciones del modelo. En SHAP, representa la esperanza de la predicción global del modelo.

Binary Features

Variables que toman únicamente dos valores posibles, normalmente codificadas como 0 y 1.

Brier Score

Métrica cuadrática que evalúa la calidad de la probabilidad predicha frente a la clase real. Cuanto menor, mejor calibrado está el modelo.

Calibración

Proceso mediante el cual se ajustan las probabilidades predichas para que reflejen frecuencias observadas reales. Se puede realizar con métodos como regresión isotónica o Platt scaling.

Categorical Features

Variables que representan clases o categorías discretas. Se transforman habitualmente mediante codificación (e.g., one-hot encoding) para ser usadas en modelos.

Class imbalance (Desbalanceo de clases)

Situación donde una clase es significativamente más frecuente que otra (por ejemplo, siniestros $\approx 4\%$). Afecta el rendimiento de los modelos y el valor de métricas como accuracy.

Confusion Matrix

Tabla que compara predicciones del modelo con las verdaderas clases. Incluye los cuadrantes TN, FP, FN y TP, a partir de los cuales se calculan múltiples métricas de rendimiento.

Cut-off (Umbral de decisión)

Valor de probabilidad a partir del cual se clasifica una observación como positiva. El ajuste de este valor tiene implicaciones sobre recall, precision y coste de errores.

Early Stopping

Técnica que detiene el entrenamiento del modelo cuando la métrica de validación deja de mejorar, previniendo sobreajuste.

Explainability (Explicabilidad)

Conjunto de métodos para interpretar cómo y por qué un modelo ha generado una predicción determinada, crucial en contextos regulados.

F1-score

Media armónica entre precision y recall. Es especialmente útil en problemas desbalanceados, ya que penaliza fuertemente cuando una de las dos es baja.

Feature Importance

Indicador del peso o relevancia de cada variable en la construcción de un modelo predictivo. Puede calcularse de forma empírica (e.g., permutación) o teórica (e.g., coeficientes).

Feature Selection

Proceso de elegir un subconjunto óptimo de variables predictoras. En este trabajo se ha realizado combinando Gini, IV, VIF, Kolmogorov-Smirnov y Permutation Importance.

Gini Coefficient

Métrica derivada del ROC-AUC, equivalente a $Gini = 2 \cdot AUC - 1$. Mide la separación entre clases en la predicción. Relacionado con el índice de Somers' D.

Gradient Boosting

Método de aprendizaje ensemble donde se ajustan modelos secuenciales para corregir el error de los anteriores. Base de algoritmos como XGBoost y LightGBM.

Hyperparameter Tuning

Proceso de búsqueda de la mejor configuración de hiperparámetros del modelo para maximizar su rendimiento. En este trabajo se realiza con Optuna.

Imputación

Proceso de rellenar valores faltantes en las variables. Puede hacerse con estrategias simples (mediana, constante) o más avanzadas.

IV (Information Value)

Métrica univariante que mide el poder predictivo de una variable categórica respecto al target. Utilizada comúnmente en scoring regulado.

LightGBM

Framework de boosting desarrollado por Microsoft. Optimiza velocidad y consumo de memoria mediante histogramas, GOSS y EFB. Ideal para grandes volúmenes.

LIME

Método local de explicabilidad. Ajusta un modelo interpretable lineal sobre observaciones perturbadas para explicar una predicción concreta.

Logistic Regression

Modelo lineal generalizado para clasificación binaria. Estima la probabilidad de ocurrencia del evento como una función logística de los predictores. Estándar en modelización de riesgo regulado.

MLOps

Conjunto de prácticas para escalar, monitorear, desplegar y mantener modelos de machine learning en producción, garantizando reproducibilidad y control.

One-Hot Encoding

Técnica de transformación de variables categóricas a vectores binarios. Cada categoría se convierte en una nueva columna con valores 0 o 1.

Optuna

Framework de optimización bayesiana de hiperparámetros basado en TPE. Implementa técnicas de early stopping y asignación adaptativa de recursos.

Overfitting

Problema en el que un modelo aprende ruido o detalles del dataset de entrenamiento, perdiendo capacidad de generalización en nuevos datos.

Permutation Importance

Método que evalúa la importancia de una variable midiendo la caída en rendimiento al permutar sus valores aleatoriamente.

Pipeline de inferencia

Secuencia de pasos aplicada a nuevos datos para generar predicciones, replicando el preprocesamiento y transformación definidos en entrenamiento.

Precision

Proporción de predicciones positivas que son realmente positivas. Penaliza los falsos positivos.

Preprocesamiento

Transformaciones aplicadas a los datos antes de su uso en un modelo. Incluye imputación, codificación, escalado, etc.

PR-AUC

Área bajo la curva Precision-Recall. Más sensible que ROC-AUC en datasets desbalanceados, ya que solo evalúa el rendimiento sobre la clase positiva.

Recalibración

Ajuste posterior de las probabilidades de un modelo para que reflejen proporciones reales. En este trabajo se usa regresión isotónica.

Recall

Proporción de verdaderos positivos detectados. Métrica clave en problemas donde no detectar un evento crítico (siniestro) tiene alto coste.

Regularización

Penalización sobre los coeficientes del modelo para evitar sobreajuste. Puede ser L1 (lasso), L2 (ridge) o combinada.

Regresión Isotónica

Técnica de calibración no paramétrica que ajusta una función monótona a la relación entre score y frecuencia observada.

Risk Modeling

Práctica de estimar cuantitativamente la probabilidad de ocurrencia de eventos adversos (e.g., siniestros) y su severidad.

ROC Curve

Curva que representa TPR vs. FPR para todos los valores posibles de umbral. Su área (AUC) refleja el poder discriminativo global del modelo.

Scale_pos_weight

Parámetro de ajuste en XGBoost/LightGBM que permite ponderar la clase positiva durante el entrenamiento.

SHAP (SHapley Additive exPlanations)

Técnica de explicabilidad global y local basada en teoría de juegos. Descompone cada predicción como suma de contribuciones individuales.

Stratify

Estrategia de muestreo que mantiene constante la proporción de clases al dividir un conjunto en entrenamiento/validación/test.

TabNet

Red neuronal especializada en datos tabulares. Utiliza mecanismos de atención secuencial y selección enmascarada de características para optimizar representación.

Target

Variable a predecir. En este caso, corresponde a la ocurrencia (1) o no ocurrencia (0) de un siniestro.

Train/Validation/Test Split

División del conjunto de datos en subconjuntos con funciones diferenciadas: entrenamiento del modelo, ajuste de hiperparámetros, y evaluación final.

TreeSHAP

Algoritmo eficiente para computar valores SHAP exactos en modelos de árboles, como XGBoost o LightGBM, sin necesidad de enumerar todas las permutaciones.

Variable de riesgo

Variable predictora que contiene información relevante para estimar la probabilidad de siniestro. Puede ser categórica, continua o binaria.

VIF (Variance Inflation Factor)

Métrica que evalúa la multicolinealidad entre variables numéricas. Un VIF elevado indica redundancia y puede afectar la estabilidad del modelo.

7. Bibliografía

- [1] He, H. & García, E.A. (2009). "Learning from Imbalanced Data." *IEEE Transactions on Knowledge and Data Engineering*.
- [2] Chawla, N.V., Bowyer, K.W., Hall, L.O. & Kegelmeyer, W.P. (2002). "SMOTE: Synthetic Minority Over-sampling Technique." *Journal of Artificial Intelligence Research*.
- [3] He, H., Bai, Y., García, E.A. & Li, S. (2008). "ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning." En *IEEE International Joint Conference on Neural Networks (IJCNN)*.
- [4] Sweeney, L. (2002). "k-anonymity: A model for protecting privacy." *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*
- [5] Dwork, C. (2006). "Differential Privacy." En *International Colloquium on Automata, Languages, and Programming (ICALP)*.
- [6] Agrawal, R. & Srikant, R. (2000). "Privacy-Preserving Data Mining." En *ACM SIGMOD International Conference on Management of Data*.
- [7] Fung, B.C.M., Wang, K., Fu, A.W.C. & Yu, P.S. (2010). "Privacy-preserving data publishing: A survey of recent developments." *ACM Computing Surveys*.
- [8] Lessmann, S., Baesens, B., Seow, H.-V. & Thomas, L.C. (2015). "Benchmarking state-of-the-art classification algorithms for credit scoring: An extended empirical study." *Journal of the Operational Research Society*.
- [9] Khandani, A.E., Kim, A.J. & Lo, A.W. (2010). "Consumer credit-risk models via machine-learning algorithms." *Journal of Banking & Finance*.
- [10] Tsai, C.F. & Wu, J.W. (2008). "Using neural network ensembles for bankruptcy prediction and credit scoring." *European Journal of Operational Research*.
- [11] Kang, Y., Jeong, Y. & Park, J. (2018). "Credit Scoring Using Imbalanced Data: A New Framework of Data Pre-Processing and Hybrid Learning." *The Journal of Intelligent Information Systems*.
- [12] Chen, T. & Guestrin, C. (2016). "XGBoost: A Scalable Tree Boosting System." En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.
- [13] Ke, G. et al. (2017). "LightGBM: A Highly Efficient Gradient Boosting Decision Tree." En *Advances in Neural Information Processing Systems (NeurIPS)*.
- [14] Friedman, J.H. (2001). "Greedy Function Approximation: A Gradient Boosting Machine." *Annals of Statistics*.
- [15] Arik, S.O. & Pfister, T. (2021). "TabNet: Attentive Interpretable Tabular Learning." En *International Conference on Learning Representations (ICLR)*.
- [16] OpenReview: TabNet
- [17] West, D. (2000). "Neural network credit scoring models." *Computers & Operations Research*.
- [18] Bellotti, T. & Crook, J. (2009). "Support vector machines for credit scoring and discovery of significant features." *Expert Systems with Applications*.

- [19] Ribeiro, M.T., Singh, S. & Guestrin, C. (2016). "Why Should I Trust You? Explaining the Predictions of Any Classifier." En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.
- [20] Lundberg, S.M. & Lee, S.-I. (2017). "A Unified Approach to Interpreting Model Predictions." En *Advances in Neural Information Processing Systems (NeurIPS)*.
- [21] Sculley, D. et al. (2015). "Hidden Technical Debt in Machine Learning Systems." En *Advances in Neural Information Processing Systems (NeurIPS)*.

8. Anexos

En los Anexos se incluyen apartados que, aunque no conllevan un salto en el proceso lógico de lectura de la memoria, proporcionan una interpretación más exhaustiva de los datos, resultados o procesos que pueden ayudar a comprender más en detalle ciertos puntos del desarrollo.

Análisis exploratorio de datos (EDA)

Análisis Bivariante: Variables Categóricas vs Target

El análisis bivariante permite observar la relación entre los niveles de cada variable cualitativa y la frecuencia del evento. En nuestro caso de uso específico, se analizan visualmente las proporciones relativas de siniestros dentro de cada categoría, lo que aporta una primera capa de entendimiento sobre el posible valor predictivo de las variables. La distribución de variables es la siguiente:

Distribución de Variables Categóricas por Target












Figura 23. Análisis bivalente. Variables categóricas “raw”

De los gráficos anteriores, se desprenden las siguientes consideraciones, a nivel genérico:

Variables con mayor poder discriminativo visual:

- **ps_car_11:** Se observa un patrón ascendente de proporción de eventos conforme aumenta el nivel, lo que podría interpretarse como una relación ordinal con el riesgo de siniestralidad.
- **ps_car_05_cat:** Se identifican diferencias claras en la proporción de Clase 1 entre los niveles -1 (miss), 0 y 1, sugiriendo que la codificación o agrupamiento puede capturar información relevante.

Variables dominadas por un solo nivel:

- **ps_ind_14, ps_ind_05_cat, ps_car_02_cat, ps_car_04_cat, ps_car_07_cat, ps_car_10_cat:** Aunque estas variables están fuertemente sesgadas hacia una

única categoría dominante, algunas muestran leves diferencias en proporciones de eventos. No deben descartarse sin una validación empírica posterior, especialmente si la clase dominante presenta un comportamiento diferencial respecto al *target*.

Variables con muchos niveles o patrón difuso:

- **ps_ind_03, ps_ind_15, ps_reg_02, ps_car_01_cat, ps_car_06_cat, ps_car_15**, y varias de las **ps_calc_xx** presentan patrones menos evidentes. Aun así, pueden contener relaciones útiles que no se aprecian a simple vista. Su análisis podría beneficiarse de *binning* supervisado o técnicas de reducción de cardinalidad.

Asimismo, sobre las variables que han entrado en los extremos de nuestro criterio/filtro inicial experto para considerar una variable cualitativa o cuantitativa entorno a los 20 niveles únicos, se observarían casos más difusos en términos de interpretación de las relaciones niveles/*target*.

Como resumen, este análisis exploratorio bivalente aporta una primera sensibilidad de carácter visual, que permite identificar variables con diferencias significativas en la distribución del *target* según sus niveles. Sin embargo, es importante destacar que la fase posterior de selección de variables se basará en un fundamento complementario empírico, donde se evaluará cuantitativamente el potencial predictivo de cada variable mediante.

De este modo, se tendrá capacidad para filtrar/desconsiderar aquellas categorías que realmente no aporten valor real a la explicación de nuestro evento. Por esa misma razón, no se exploran/explotan técnicas de representación visual más avanzadas, pues será empíricamente como se identifique la capacidad de cada variable para explicar dicho evento, con el objetivo de seleccionar obtener subconjunto del total más acotado, más explicable/manipulable y con potencial poder discriminante sobre el *target*.

Análisis Bivalente: Variables Cuantitativas vs Target

Este apartado explora la relación entre las variables continuas y la variable objetivo (evento de siniestralidad) a través de histogramas de densidad superpuestos. Se busca detectar diferencias en la forma, tendencia central o dispersión entre ambas clases, lo cual puede sugerir un potencial poder predictivo.

Distribución de Variables Continuas por Target




Figura 24. Análisis bivalente. Variables cuantitativas “raw”

De los gráficos anteriores, se desprenden las siguientes consideraciones, a nivel genérico:

Variables con diferencias visuales claras entre clases

- **ps_reg_03, ps_car_13, así como ps_calc_10 y ps_calc_14** (por su mero comportamiento normal y diferenciado entre el evento), son distribuciones donde el evento puede aportar relevancia en modelos sensibles a la distribución.

Variables con patrones menos claros o dominadas por picos

- **ps_car_11_cat:** Exhibe una gran cantidad de valores discretos con una frecuencia extrema en un único punto (entorno al valor 100). La Clase 1 “evento” parece estar algo más distribuida.
- **ps_car_12 y ps_car_14:** Están dominadas por valores puntuales o discretos con alta frecuencia. Aunque las diferencias no son visualmente pronunciadas, podrían contener valor tras transformación.

En general, las diferencias entre clases no son tan evidentes como en algunas variables de naturaleza cualitativa vistas en el bivalente anterior. Sin embargo, visualizamos un conjunto de variables numéricas más reducido que con técnicas de normalización/escalado, pueden aportar poder predictivo al caso de uso.

Todo ello, es posible ya que el análisis bivalente nos permite detectar ligeros desplazamientos o cambios en la forma de la distribución del target. Aunque estas

diferencias son, en la mayoría de los casos, sutiles a nivel visual, ofrecen una primera aproximación sobre la capacidad de segmentación del riesgo.

Esta fase visual actúa como una primera capa evaluadora, especialmente útil para identificar transformaciones necesarias y comprender el comportamiento del *target* dentro del rango de cada variable, si bien la capa posterior de preparación y selección será la definitiva frente a variables que realmente son discriminantes.

Selección de Variables – Cálculo de indicadores por variable

Cálculo de indicadores por variable

Coeficiente de Gini

El coeficiente de Gini es una métrica fundamental para evaluar la capacidad discriminante de una variable respecto a un objetivo binario. Altamente usada en problemas de riesgo de crédito, extendemos su uso en el proyecto para evaluar el poder discriminante de las variables contra el *target* binario de siniestro. La métrica, deriva del área bajo la curva ROC (AUC), siendo robusta al tomar en cuenta cuan sensible y específico es el clasificador. Se calcula como:

$$GINI = 2 \cdot AUC - 1$$

Este coeficiente refleja la capacidad de una variable para distinguir entre eventos y no eventos, siendo especialmente, tal y como se ha comentado, útil en contextos de modelización del riesgo. El Gini está estadísticamente relacionado con el estadístico de Somers' D, de forma que:

$$GINI = Somers' D$$

El Somers' D mide la fuerza y dirección de la asociación entre una variable predictora X y el estado objetivo (siniestro/no siniestro). Formalmente:

$$Somers' D = P(X_{no\ siniestro} < X_{siniestro}) - P(X_{no\ siniestro} > X_{siniestro})$$

Es decir, la diferencia entre la probabilidad de que un no siniestro tenga un score menor que un siniestro y la probabilidad de lo contrario. A tener en cuenta:

- Somers'D puede ser positivo o negativo, reflejando el sentido de la asociación.
- Si $D > 0$, el predictor asigna mayores scores a los siniestros, como deseamos.
- Si $D < 0$, el predictor discrimina en sentido inverso (lo cual puede requerir invertir el signo o reconsiderar la variable).

Consideraciones específicas:

Aplicabilidad:

- **Tipo de variables:** se aplicará sobre todas las variables, tanto cualitativas como cuantitativas. En el caso de variables multinivel, se realizará una transformación mediante *one-hot encoding* para evaluar el poder discriminante a nivel de cada categoría. Esta estrategia permite descomponer una variable categórica en múltiples variables binarias, capturando la información individual de cada nivel de forma explícita.
- **Tratamiento de valores faltantes:** Dado que en este conjunto de datos los valores faltantes se codifican como -1, se realizará una conversión explícita a NaN antes de calcular el AUC. Esto es necesario porque la función `roc_auc_score` de `scikit-learn` no admite NaN como entrada, y porque mantener el -1 podría introducir un sesgo significativo en la medición de la capacidad discriminativa de la variable.
- **Criterio de selección:** El coeficiente de Gini no se utilizará como umbral absoluto según los valores establecidos en la literatura (e.g., $Gini > 0.3$ indica buena capacidad predictiva), sino como una métrica relativa dentro del conjunto de variables analizadas.

Este procedimiento permite identificar variables que presentan una estructura informativa/discriminante relevante respecto al target, incluso si su relación no es lineal ni monótonica. Su valor añadido radica en que permite evaluar la capacidad discriminativa sin asumir ningún modelo subyacente.




Figura 25. Gini de las variables del conjunto de datos

Information Value (IV)

El *Information Value* (IV), junto con el *Weight of Evidence* (WoE), es una de las métricas más utilizadas para evaluar la capacidad predictiva de una variable independiente respecto a una

variable objetivo binaria. Estas métricas, derivadas de la teoría de la información, son ampliamente aplicadas en contextos de riesgo de crédito.

Por un lado, el WoE mide el grado de separación entre las distribuciones de las dos clases de la variable objetivo ($Y=1$ vs $Y=0$) dentro de cada grupo o *bin* de una variable independiente X . Se calcula como:

$$WOE_j = \ln \left(\frac{\frac{N_{0j}}{N_0}}{\frac{N_{1j}}{N_1}} \right)$$

Con:

- N_{1j} : número de siniestros en el grupo j
- N_{0j} : número de no siniestros en el grupo j
- N_1, N_0 : totales de eventos y no eventos (siniestralidad) en el *dataset*, respectivamente

Un $WoE = 0$ indica proporciones idénticas entre clases (no información), mientras que un $WoE < > 0$ define un mayor peso del grupo hacia cada una de las clases del evento. Finalmente, el IV se define como:

$$IV = \sum_{i=1}^n \left(\frac{N_{0j}}{N_0} - \frac{N_{1j}}{N_1} \right) \cdot WOE_j$$

Consideraciones específicas:

Aplicabilidad:

- **Tipo de variables:** se aplicará sobre todas las variables, tanto cualitativas como cuantitativas.
- **Tratamiento de valores faltantes:** se preservan los nulos reales (convertidos a NaN), diferenciándolos del valor -1. Esta elección permite que el modelo distinga efectivamente los casos con ausencia de información sin introducir sesgo al tratar -1 como una categoría legítima.
- **Transformación:** las variables continuas se binarizan mediante *binning* cuantílico (percentiles) para obtener grupos que preserven la distribución y permitan un cálculo estable del WoE e IV.
- **Criterio de selección:** el IV se utilizará como métrica relativa en el conjunto de variables, no como umbral absoluto, tal y como se ha hecho en el caso del Gini.

Este procedimiento permite identificar variables que presentan una estructura informativa relevante respecto al target, incluso si su relación no es lineal ni monotónica. Su valor añadido radica en que permite evaluar la capacidad discriminativa sin asumir ningún modelo subyacente.




Figura 26. IV de las variables del conjunto de datos

Importancia por permutación

La Importancia por Permutación es una técnica ampliamente adoptada en *Machine Learning* para evaluar la relevancia de cada variable en la predicción del modelo. Su principio es simple, pero de ahí radica su potencial: desordenar (permutar aleatoriamente) los valores de una variable y observar la degradación del rendimiento del modelo.

Este método es especialmente eficaz en modelos no lineales como *Random Forest*, *Gradient Boosting* o Redes Neuronales, ya que permite capturar relaciones complejas sin asumir estructuras paramétricas. En el presente caso de uso, se usará *Random Forest*, si bien la elección no sigue ningún prejuicio más que tener un mismo modelo sobre el que contrastar el deterioro del predictor de cara a evaluar la importancia. Formalmente, la importancia:

$$\text{Importancia}(X_j) = E[L(f(X^{(j)}), y) - L(f(X), y)]$$

Donde:

- f es el modelo predictivo,
- $X^{(j)}$ es la matriz de predictores X con la variable X_j permutada aleatoriamente,
- y es el vector de etiquetas (0 = no siniestro, 1 = siniestro),
- L es una función de pérdida (por ejemplo, log-loss o error de clasificación).

Interpretación:

Si la permutación de X_j degrada significativamente el modelo, X_j es importante para la predicción de siniestros. Contrariamente, si X_j apenas tiene afectación en el performance medido, probablemente sea irrelevante.

Consideraciones específicas:

Aplicabilidad:

- **Tipo de variables:** todas las variables del dataset, tanto cualitativas (binarizadas) como cuantitativas, son incluidas en la evaluación.
- **Tratamiento de valores faltantes:** se preservan los nulos reales (convertidos a NaN), diferenciándolos del valor -1. Esta elección permite que el modelo distinga efectivamente los casos con ausencia de información sin introducir sesgo al tratar -1 como una categoría legítima.

Criterio de uso: la importancia obtenida se utilizará como medida relativa para comparar variables entre sí dentro del conjunto, sin aplicar un umbral absoluto. Este enfoque se alinea con la filosofía aplicada previamente al Information Value y al Gini, buscando consistencia metodológica en la selección final de atributos relevantes.




Figura 27. *Permutation Importance* de las variables del conjunto de datos

Variance Inflation Factor (VIF)

El VIF evalúa la multicolinealidad entre predictores continuos, lo que puede distorsionar la interpretación de modelos lineales. Para la variable X_j , se define:

$$VIF_j = \frac{1}{1 - R_j^2}$$

Donde R_j^2 es el coeficiente de determinación de una regresión lineal de contra todas las demás variables. Notas específicas:

- El fenómeno que modelamos (siniestro / no siniestro) no se ve directamente afectado por el VIF.
- Sin embargo, predictores altamente correlacionados pueden inflar varianzas de los coeficientes y dificultar la interpretación de los efectos marginales sobre la probabilidad de siniestro.

Consideraciones específicas:

Aplicabilidad:

- **Tipo de variables:** únicamente se aplicará sobre variables continuas, ya que el concepto de varianza inflada se define en el contexto de regresión lineal.
- **Tratamiento de valores nulos:** se eliminan los registros con valores NaN en las variables continuas antes del cálculo del VIF, para evitar errores numéricos.
- **Criterio de selección:** aquellas variables que presenten VIF elevados serán eliminadas del conjunto final de predictores, con el objetivo de reducir la redundancia y mejorar la estabilidad del modelo.




Figura 28. VIF de las variables cuantitativas del conjunto de datos

Kolmogorov-Smirnov (KS)

El KS test compara las distribuciones de una variable entre dos poblaciones: no siniestros y siniestros. El estadístico D se define como:

$$D = \sup |F_{no\ siniestro}(x) - F_{siniestro}(x)|$$

Donde:

- $F_{no\ siniestro}(x)$ es la función de distribución acumulada empírica de los no siniestros,
- $F_{siniestro}(x)$ es la función de distribución acumulada empírica de los siniestros,
- $\sup$ denota el máximo valor absoluto.

Interpretación:

- D mide la máxima distancia vertical entre las dos CDFs.
- D cercano a 1 indica que la variable separa bien siniestros de no siniestros.
- D cercano a 0 indica mala discriminación.

El KS puede considerarse como una medida no paramétrica de poder separador sobre la variable.

Consideraciones específicas:

Aplicabilidad:

- **Tipo de variables:** el test se aplicará exclusivamente a variables continuas, ya que su definición se basa en funciones de distribución acumulada.
- **Tratamiento de valores nulos:** se eliminan los registros con valores NaN en las variables continuas antes del cálculo del estadístico, para no alterar la forma de las distribuciones.




Figura 29. KS de las variables cuantitativas del conjunto de datos

OPTUNA - detalle:

Enfoque metodológico: TPE + Pruning

El motor principal de Optuna se basa en el algoritmo TPE (Tree-structured Parzen Estimator), que es una técnica de optimización bayesiana no paramétrica. Dado un espacio de hiperparámetros Θ , TPE modela dos distribuciones de probabilidad:

- $l(\theta)$: la distribución de los hiperparámetros que conducen a buenas evaluaciones (i.e., AUC alto)
- $g(\theta)$: la distribución de los hiperparámetros restantes.

A cada iteración, se selecciona la muestra $\theta \in \Theta$ que maximiza la razón de verosimilitud inversa:

$$\theta^* = \arg \max_{\theta} \frac{l(\theta)}{g(\theta)}$$

Esto permite centrar la búsqueda en zonas del espacio con mayor probabilidad de rendimiento óptimo.

Mecanismo de pruning (early stopping)

Optuna incluye además un mecanismo interno de *pruning*, que descarta tempranamente combinaciones de hiperparámetros cuyo rendimiento intermedio no sugiere mejora respecto al óptimo actual. Esto permite reducir el número de evaluaciones completas y ahorrar recursos computacionales.

Formalización del problema

El proceso de optimización puede formalizarse como:

$$\theta^* = \operatorname{argmax} \operatorname{AUC}_{\text{val}}(f(X; \theta))$$

Donde:

- $f(X; \theta)$ es el modelo entrenado con los hiperparámetros θ
- $\operatorname{AUC}_{\text{val}}$ es el AUC medido sobre el conjunto de validación.

Este planteamiento se implementa mediante funciones objetivo específicas por modelo, evaluadas de forma iterativa por el motor de búsqueda.

El uso de Optuna, combinado con la maximización del AUC como criterio de rendimiento, permite adaptar cada modelo a nuestro planteamiento específico de estimación de siniestralidad, donde el desbalance de clases, la heterogeneidad de las variables y las restricciones interpretativas hacen imprescindible un ajuste fino y controlado de los hiperparámetros.

Este proceso no es accesorio, sino que forma parte central del diseño del modelo predictivo, condicionando su arquitectura, su capacidad de generalización y, en última instancia, su utilidad práctica en contextos reales de riesgo asegurador o financiero.

Espectro de Hiperparámetros y valor final tras Optuna

Se muestran los hiperparámetros definidos por valor o rango, y el valor óptimo estimado por Optuna:

Modelo	Hiperparámetro	Explicación	Rango	Valor Optuna
Regresión Logística	C	Control de capacidad/fuerza de regularización (valores bajos = más penalización)	0.01 – 10	5,37
	class_weight	Ajuste del peso en clases desbalanceadas	"balanced"	–
	solver	Algoritmo numérico de optimización	["lbfgs", "liblinear"]	liblinear
	max_iter	Iteraciones máximas en la optimización	–	–
	model.fit	Sin métricas internas: la evaluación se realiza externamente	–	–
XGBoost	n_estimators	Número de árboles	50 – 500	473
	max_depth	Profundidad máxima	3 – 12	4
	learning_rate	Tasa de aprendizaje	0.005 – 0.3	0,0057
	scale_pos_weight	Peso de la clase positiva según el desbalance	Fijado	–
	subsample	Fracción de muestras por árbol	0.6 – 1.0	0,88
	colsample_bytree	Fracción de variables por árbol	0.6 – 1.0	0,6
	gamma	Penalización de complejidad	0 – 5	1,68
	reg_alpha	Regularización L1	0 – 1	0,73
	reg_lambda	Regularización L2	0 – 1	0,5
	model.fit[eval_set]	Conjunto de validación [(X_test, y_test)]	–	–
	model.fit[eval_metric]	Métrica a monitorizar	–	–
	model.fit[early_stopping_rounds]	Detención anticipada tras 50 iteraciones sin mejora	–	–
LightGBM	num_leaves	Número máximo de hojas	10 – 100	28
	learning_rate	Tasa de aprendizaje	0.005 – 0.3	0,022

Tabnet	n_estimators	Número de árboles	50 – 500	277
	is_unbalance	Compensación automática de clases	True	–
	feature_fraction	Fracción de variables por iteración	0.6 – 1.0	0,6
	lambda_l1	Regularización L1	0.0 – 1.0	0,5
	lambda_l2	Regularización L2	0.0 – 1.0	0,15
	model.fit[eval_set]	Conjunto de validación [(X_test, y_test)]	–	–
	model.fit[eval_metric]	Métrica de evaluación	–	–
	model.fit[objective]	Binary: obligatorio para clasificación binaria	–	–
	n_d, n_a	Dimensión de decisión y atención	8 – 64	58 y 64
	n_steps	Pasos de decisión	3 – 10	10
	gamma	Penalización por complejidad	1.0 – 2.0	1,02
	lambda_sparse	Regularización L1 para sparsity	0.001 – 0.1	0,003
	momentum	Suavizado en actualizaciones	0.02 – 0.98	0,52
	model.fit[eval_set]	Requiere arrays NumPy [(X_test, y_test)]	–	–
	model.fit[eval_metric]	Métrica para monitorizar mejora	–	–
	model.fit[patience]	Parada temprana tras N iteraciones sin mejora	–	–
	model.fit[max_epochs]	Número máximo de épocas	–	–
	model.fit[batch_size]	Tamaño del batch	–	–
	model.fit[virtual_batch_size]	Batch virtual para normalización	–	–
En azul sombreado aquellas instancias del fit que no son hiperparms.				

Tabla 9. Espectro de hiperparámetros considerado por modelo y valor final tras Optuna.

Proceso de entrenamiento – Interpretación de resultados

Métricas de error para Datos Desbalanceados sobre target binario

Este apartado se implementa con el objetivo de robustecer en todo momento las consideraciones que puedan derivarse del resultado del entrenamiento de los modelos. La correcta interpretación de métricas es esencial para concluir el ajuste del modelo. En nuestro caso específico, el procedimiento nominal en la evaluación del error de un planteamiento de clasificación binaria pasa por la evaluación lógica de la matriz de confusión. Esta matriz nos permite obtener información acerca del ajuste de nuestro clasificador, en función de cómo este se haya desempeñado (predicción), en contraste con la realidad (actual/real).

En ese contexto, es necesario tener en cuenta que la matriz de confusión es simplemente un *snapshot* del *cut-off* óptimo que cada solución cuantitativa ha adoptado. Por esa razón, las métricas que consideran la totalidad del rango de confianza (0–1), en lo relativo a su clasificación, son las que deben considerarse en una primera fase de selección del mejor clasificador en términos relativos a los contemplados como potenciales opciones.

Estas métricas (como ROC-AUC o PR-AUC), nos proporcionan una imagen completa sobre el desempeño del modelo, a partir del análisis de la distribución de métricas extraídas de la matriz de confusión, pero observadas a lo largo de todos los posibles valores de corte.

Idiosincrasia de la Matriz de Confusión vs. Métricas AUC como elemento clave

Uno de los aspectos más críticos —y frecuentemente que suelen ser malinterpretados— en la evaluación de modelos de clasificación binaria tanto sobre *datasets* desbalanceados como

a nivel más genérico, es el carácter puntual y condicional de la matriz de confusión frente al carácter global y marginal de métricas como ROC-AUC y PR-AUC.

Como se cita anteriormente, la matriz de confusión representa una única *snapshot* del rendimiento del modelo para un umbral de decisión (*cut-off*) específico, normalmente atribuido como el óptimo o el valor arbitrario 0.5.

Con carácter genérico, dado un score de probabilidad generado por el modelo para cada observación, se fija un umbral (por ejemplo, el propio 0.5), y a partir de este se decide si una observación pertenece a la clase positiva o negativa. Formalmente:

$$y_i = 1 \text{ si } P(y = 1|x_i) \geq \tau$$

$$y_i = 0 \text{ si } P(y = 1|x_i) < \tau$$

Este valor de corte define completamente la matriz de confusión en cada una de sus celdas (TP, FP, TN, FN) y por tanto todas las métricas asociadas a ella como precisión, *recall*, especificidad, F1-score, etc. Sin embargo, esta visión es parcial, ya que solo representa el rendimiento en ese único punto de decisión, y no captura el comportamiento del modelo ante distintas decisiones en función del umbral de corte.

En términos más estadísticos, la matriz de confusión es condicional al *cut-off* elegido, mientras que ROC-AUC y PR-AUC son incondicionales, ya que consideran todo el soporte del score de clasificación. Las métricas ROC-AUC y PR-AUC evalúan la capacidad discriminante del modelo sobre todos los posibles umbrales $\tau \in [0,1]$. En lugar de tomar una decisión de clase directa, estas métricas utilizan los scores continuos generados por el modelo para construir curvas que integran la variación del rendimiento:

- ROC-AUC: Área bajo la curva ROC (TPR vs. FPR) al variar el umbral τ .
- PR-AUC: Área bajo la curva *Precision* vs. *Recall* al variar el umbral τ .

Estas métricas no conllevan fijar ningún umbral, por lo que ofrecen una evaluación agregada y robusta de la capacidad predictiva del modelo, independientemente del corte elegido.

Mientras que una matriz de confusión responde a ¿*Qué tal clasifica el modelo con un τ fijo?*, el AUC responde a ¿*Cuánto mejor es capaz el modelo de clasificar mejor que una predicción aleatoria, considerando todos los posibles τ ?*

Consideraciones específicas:

Integración con los resultados soluciones predictivas adoptadas:

La diagnosis de cuan bien clasifica un modelo de clasificación debe realizarse entorno a las métricas AUC, pues son incondicionales al umbral (que solamente puede optimizarse a nivel de negocio tal y como se verá justamente al final del caso de uso).

La métrica ROC-AUC, pondera por igual la tasa de verdaderos positivos (TPR) y la tasa de falsos positivos (FPR). Esta simetría puede ser controvertida cuando la clase positiva es escasa, ya que incluso una mejora significativa en la detección de siniestros puede no reflejarse adecuadamente

en el valor del ROC-AUC. En ese contexto, aunque ROC-AUC nos proporciona de manera generalizada la separación de ambas clases en el clasificador (poder discriminante), y se establece como principal métrica objetivo dado el problema del clasificador binario. Por otro lado, la PR-AUC (área bajo la curva *Precision-Recall*) en nuestro caso también nos aporta información relevante ya que:

- Se centra exclusivamente en la clase positiva (siniestros).
- Ignora la clase mayoritaria, evitando el sesgo del desequilibrio.
- Es más sensible a mejoras reales en la detección de eventos poco frecuentes.

Para tener una visión holística y contrastar soluciones analíticas de forma robusta, las métricas AUC (tanto `roc_auc_score` como `average_precision_score` según paquetería `scikit learn`) deben ser el criterio principal. A partir de estas, se puede luego descender al detalle puntual de una matriz de confusión para interpretar casos concretos y calcular métricas más aplicables a negocio (por ejemplo, tasa de siniestros correctamente identificados a un coste aceptable de falsos positivos).

Matriz de confusión: Precision y Recall como métricas clave en un clasificador desbalanceado

Una vez tenemos un modelo concreto, con una AUC (ROC-PR) definida, la interpretación de la matriz de confusión en sus distintos cortes nos permitirá ajustar el umbral de decisión según las voluntades específicas de nuestro planteamiento. Por ejemplo, si un falso siniestro predicho es crítico, o es más crítico un siniestro real que no se ha predicho.

Es en ese contexto y particularmente en nuestro caso, donde las métricas que ponderan por igual ambas clases (como la *accuracy*), pueden llevar a interpretaciones erróneas sobre el correcto rendimiento que realmente está realizando el modelo.

Por ello, se hace necesario desplazar el foco hacia métricas que reflejen con mayor fidelidad la capacidad del modelo de identificar correctamente la clase minoritaria (siniestros), sin que la clase mayoritaria (no siniestros) distorsione la evaluación.

Supongamos que un modelo predice todo como clase negativa. En un *dataset* como el nuestro con 96% de clase 0 (no siniestro), se obtendría un *accuracy* del 96% sin haber detectado ningún siniestro ($TP = 0$), lo cual es completamente incorrecto desde el punto de vista del negocio.

En estas situaciones, *precision* y *recall* aplicadas sobre la clase positiva son métricas fundamentales:

- **Precision:** proporción de las predicciones positivas son realmente siniestros:

$$Precision = \frac{TP}{FP + TP}$$

- **Recall (TPR):** proporción de siniestros reales ha sido detectada

$$Recall = \frac{TP}{FN + TP}$$

El compromiso entre ambas se sintetiza en el F1-score, siendo la media armónica entre ambas métricas que penaliza por tanto fuertemente cuando una de las dos métricas es baja.

Una vez tengamos bien definido el clasificador, se va a llevar a cabo un ejercicio que pasará por visualizar la capacidad de nuestro clasificador y tener consciencia situacional de como este se desempeña en cada uno de los umbrales de *cut-off*, siendo este uno de los puntos más valiosos tras el entrenamiento, pues corresponde a la extrapolación total del modelo con el problema de negocio.

Calibración de la curva de probabilidad

Regresión Isotónica

La regresión isotónica es una técnica no paramétrica utilizada para modelar una función monótona creciente a partir de datos empíricos. Su aplicación más relevante en problemas de clasificación binaria es la calibración de probabilidades, ajustando la salida de un modelo predictivo para que refleje correctamente la probabilidad empírica de ocurrencia del evento positivo.

Sea un conjunto de pares ordenados $((s_i, y_i))$, donde (s_i) es el score generado por un modelo (la salida de XGBoost antes de aplicar el umbral en nuestro caso) y (y_i) entre $\{0,1\}$ la clase real observada. La regresión isotónica busca una función monótona creciente (f) que minimice el error cuadrático medio entre la predicción calibrada y la clase real:

$$\min_{f \in M} \sum_{i=1}^n (f(s_i) - y_i)^2 \quad \text{donde } M = \{f \text{ monótona creciente}\}$$

Este ajuste se realiza típicamente mediante el algoritmo de *Pool Adjacent Violators* (PAV), que encuentra la mejor aproximación por tramos constantes no decrecientes. Esta técnica es no paramétrica, lo que la hace especialmente flexible frente a distribuciones sesgadas o altamente desbalanceadas, como ocurre en riesgo de siniestralidad (nuestro caso de uso). Asimismo:

- No impone forma funcional sobre la relación entre el score y la probabilidad real, siendo ideal en problemas donde esta relación puede ser *piecewise* o no sigmoidea.
- Permite una interpretación probabilística más fiel, especialmente en regiones donde el modelo original tiende a sobreestimar o infraestimar riesgos.
- Su naturaleza no paramétrica implica mayor flexibilidad, aunque también mayor riesgo de sobreajuste si el conjunto de calibración es pequeño o poco representativo.

En cualquier planteamiento de medición del riesgo, es común encontrar modelos que ordenen bien, pero que fallan en traducir estos scores a probabilidades calibradas. En estos casos, *isotonic regression* actúa como una capa *post-hoc* que transforma los scores en una escala probabilística más realista, sin modificar el modelo original.

Este método constituye una herramienta potente cuando se requiere interpretar la salida del modelo como una probabilidad fiable. Su uso es especialmente relevante en entornos regulados o de alta criticidad (como seguros o crédito), donde las decisiones no solo deben ser correctas, sino cuantitativamente justificables.

Aplicación sobre el mejor modelo en el contexto del proyecto

El modelo XGBoost, al igual que otros algoritmos basados en *gradient boosting*, tiende a producir valores extremos (muy cercanos a 0 o 1) en sus predicciones probabilísticas, lo que implica una sobre confianza en sus decisiones. A pesar de obtener buenos valores de ROC-AUC, su output no refleja necesariamente probabilidades empíricas bien calibradas.

Por tanto, es razonable aplicar un método de calibración *post-hoc* que mapea los scores del modelo a probabilidades reales observadas. Una solución robusta y ampliamente aceptada es el uso del *wrapper* de scikit-learn `CalibratedClassifierCV`, que permite calibrar cualquier estimador compatible con el método `predict_proba`, como es el caso de `XGBClassifier`.

Este *wrapper* permite calibrar el modelo en una estrategia de validación cruzada o en un conjunto de validación separado, ajustando una función de calibración como en este caso isotónica. La calibración se realiza sin reentrenar completamente el modelo base, simplemente ajustando una capa superior de transformación probabilística. De este modo, se conserva el poder predictivo del modelo original, pero con una salida más alineada con la frecuencia real de ocurrencia del evento positivo, lo cual es crítico para tareas de toma de decisión reguladas o sensibles. Asimismo:

- Permite mantener la estructura y parámetros del modelo XGBoost entrenado.
- No requiere modificaciones al preprocesamiento ni al pipeline ya entrenado.
- Mejora la interpretabilidad y confiabilidad de la probabilidad como score final.

Explicabilidad (LIME y SHAP)

Interpretación local del modelo mediante LIME (Local Interpretable Model-agnostic Explanations)

Antes de abordar técnicas de explicabilidad globales como SHAP, es relevante introducir el método LIME, una de las herramientas pioneras y más utilizadas en el ámbito de la explicabilidad local de modelos complejos. LIME proporciona una manera de entender el comportamiento de un modelo de tipo “caja negra” en torno a una observación concreta, sin necesidad de acceder a su estructura interna.

El principio de LIME se basa en la idea de aproximar localmente el modelo complejo mediante un modelo interpretable, típicamente lineal, en el vecindario de la instancia que se desea explicar. Esto se logra a través de los siguientes pasos:

- Generación de datos sintéticos: se crean perturbaciones (vecinos) alrededor de la observación x_0 que se desea interpretar, modificando ligeramente sus valores.
- Evaluación del modelo original: se calcula la predicción del modelo complejo sobre estos datos perturbados.
- Ponderación por proximidad: se asignan pesos a las perturbaciones según su cercanía a x_0 normalmente mediante una función de *kernel* gaussiano.
- Ajuste de un modelo interpretable $g(x)$: se entrena un modelo lineal ponderado sobre el vecindario generado, para aproximar f cerca de x_0

Formalmente, LIME optimiza:

$$\arg \min_{g \in G} H(f, g, a_{x_0}) + \Omega(g)$$

Donde

- H es la pérdida de fidelidad entre el modelo complejo f y el modelo interpretable g
- a_{x_0} es la distribución de pesos centrada en cada x_0
- $\Omega(g)$ penaliza la complejidad de g garantizando su interpretabilidad (e.g., número de variables usadas).
- G es la familia de modelos interpretable (e.g., regresión lineal escasa).

Características y ventajas

- **Localidad pura:** LIME explica cada predicción individualmente, sin asumir estructura global.
- **Modelo-agnóstico:** no requiere acceso al modelo interno ni a sus gradientes; funciona con cualquier sistema que genere scores.
- **Flexibilidad:** permite usar modelos explicativos distintos (regresión, árboles pequeños, reglas, etc.).

Limitaciones

- La aproximación lineal puede no capturar bien regiones no lineales incluso localmente, especialmente en vecindarios con alta complejidad.
- Resultados no consistentes entre ejecuciones, debido a la aleatoriedad de la generación de datos sintéticos.
- Sensibilidad al tamaño del vecindario y a la forma del kernel, lo que puede afectar la fidelidad de la explicación.

En el presente trabajo, LIME se utiliza como herramienta de diagnóstico local para analizar casos individuales en los que la predicción del modelo es crítica, permitiendo visualizar qué variables están activando el score de siniestralidad en cada cliente concreto. Aunque no proporciona interpretaciones globales ni garantiza aditividad, su valor práctico reside en la comprensión puntual y rápida del razonamiento subyacente del modelo, especialmente útil en contextos de revisión operativa o validación manual de casos frontera.

Interpretación del modelo mediante SHAP

SHAP se basa en los valores de Shapley, introducidos en teoría de juegos cooperativos por Lloyd Shapley (1953). La idea central es asignar a cada variable una contribución justa al resultado de una coalición (predicción del modelo), considerando todas las combinaciones posibles con las demás variables.

Formalmente, sea $f(x)$ la predicción de un modelo complejo y $x = (x_1, x_2, \dots, x_p)$ el vector de entrada. SHAP descompone la predicción $f(x)$ como:

$$f(x) = \phi_0 + \sum_{j=1}^p \phi_j$$

Donde ϕ_0 es el valor esperado del modelo (baseline) y ϕ_j es la contribución marginal esperada de la variable (x_j) a la predicción final.

Una de las ventajas clave de SHAP es que permite una implementación exacta y eficiente en árboles de decisión, como los utilizados por XGBoost, mediante el algoritmo TreeSHAP. Esta implementación permite calcular los valores sin tener que recorrer todas las combinaciones posibles (de coste exponencial), lo que hace que su uso sea práctico incluso en contextos productivos o *datasets* de alta dimensión. El método permite dos niveles de interpretación:

Local (por observación):

- Se analiza cómo cada variable específica contribuye al score de una observación concreta.
- Se puede visualizar como una fuerza que empuja la predicción por encima o por debajo del valor base
- Útil para justificar decisiones individuales o detectar casos atípicos.

Global (agregado):

- Se resumen las contribuciones absolutas promedio de cada variable sobre el conjunto de datos.
- Esto permite obtener un ranking de importancia más robusto y explicativo que el `feature_importances` tradicional.
- Facilita la validación del modelo respecto a hipótesis de negocio o intuiciones expertas.

En comparación con técnicas alternativas como LIME, SHAP tiene una base teórica más sólida, produce explicaciones consistentes y unificadas para todos los tipos de modelos, y sus valores pueden ser interpretados como atribuciones proporcionales y equitativas al resultado del modelo. Además, en contextos regulados, su trazabilidad y solidez matemática son especialmente valoradas.

Página intencionadamente en
blanco